UNIVERSIDAD DE SALAMANCA

FACULTAD DE CIENCIAS

GRADO EN ESTADÍSTICA

TRABAJO DE FIN DE GRADO

"COMPARACIÓN DE ALGORITMOS DE IMPUTACIÓN DE DATOS FALTANTES EN GRANDES BASES DE DATOS BIOMÉDICAS"

Autor:
Jorge Otaduy Pérez

Tutor:

Pedro Ignacio Dorado Díaz

SALAMANCA, JULIO DE 2025

UNIVERSIDAD DE SALAMANCA

FACULTAD DE CIENCIAS

GRADO EN ESTADÍSTICA

TRABAJO DE FIN DE GRADO

"COMPARACIÓN DE ALGORITMOS DE IMPUTACIÓN DE DATOS FALTANTES EN GRANDES BASES DE DATOS BIOMÉDICAS"

Autor:
Jorge Otaduy Pérez

Firma:

*Firmado por OTADUY PEREZ JORGE - ***0504** el día 04/07/2025 con un certificado emitido por AC FNMT Usuarios*

SALAMANCA, JULIO DE 2025

Certificado del tutor del TFG

D. Pedro Ignacio Dorado Díaz, profesor del Departamento de Estadística de la Universidad de Salamanca,

HACE CONSTAR:

Que el trabajo titulado “Comparación de algoritmos de imputación de datos faltantes en grandes bases de datos biomédicas” que se presenta, ha sido realizado por Jorge Otaduy Pérez con DNI 70905047A y constituye la memoria del trabajo desarrollado para la superación de la asignatura Trabajo de Fin de Grado en Estadística en esta Universidad.

Salamanca, a fecha de firma electrónica.

DORADO DIAZ, PEDRO IGNACIO (FIRMA)

Firmado digitalmente por DORADO DIAZ, PEDRO IGNACIO (FIRMA)
Fecha: 2025.07.04 22:01:23 +02'00'

Fdo.: PEDRO IGNACIO DORADO DÍAZ

ÍNDICE

Resumen

Abstract

1. Introducción 1

1.1. La problemática de los valores faltantes 1

1.2. Motivación del trabajo 1

1.3. Objetivos 2

1.4. Metodología general del estudio 2

1.5. Estructura del trabajo 3

2. Marco teórico y estado del arte 4

2.1. Tipos de mecanismos de ausencia 4

2.2. Técnicas de imputación de valores faltantes 6

2.3. Impacto de la imputación en modelos de machine learning 10

2.4. Evaluación de imputación en la literatura: métricas y criterios 12

2.5. Benchmarks anteriores y trabajos relevantes 13

2.6. Contribución del presente trabajo 14

3. Material y métodos 16

3.1. Descripción del dataset NHANES 16

3.2. Selección de variables y procesamiento inicial 18

3.3. Variable objetivo y tipo de tarea 20

3.4. Simulación controlada de valores faltantes 21

3.5. Métodos de imputación utilizados 23

3.6. Modelos de aprendizaje utilizados 24

3.7. Métricas de evaluación 25

3.8. Diseño experimental 26

4. Resultados 28

4.1. Comparativa global de métodos de imputación 28

4.2. Resultados según mecanismo y porcentaje de valores faltantes 29

4.3. Variabilidad y estabilidad de las imputaciones 31

4.4. Comparación de los modelos predictivos por método de imputación 33

4.5. Impacto del balanceo de clases (SMOTE) 34

4.6. Síntesis visual de los resultados experimentales 35

5. Discusión **39**

5.1. Análisis crítico de los resultados 39

5.2. Limitaciones del diseño experimental 41

5.3. Comparación con estudios anteriores 42

5.4. Aplicabilidad en entornos clínicos y epidemiológicos 43

6. Conclusiones **44**

6.1. Principales hallazgos del estudio 44

6.2. Recomendaciones sobre imputación en datos biomédicos 45

6.3. Propuesta de mejoras metodológicas 46

6.4. Proyectos futuros 47

7. Bibliografía

ÍNDICE DE TABLAS

Tabla 1: Variables representativas del conjunto de datos NHANES 17
Tabla 2: Variables eliminadas en la primera limpieza (27 en total) 18
Tabla 3: Variables eliminadas en la segunda limpieza (12 en total) 19
Tabla 4: Variables eliminadas en la tercera limpieza (3 en total) 19
Tabla 5: Métodos de imputación utilizados: tipo, implementación y aplicación 23
Tabla 6: Rendimiento medio de los métodos de imputación en test (ordenado por F1-score) 28
Tabla 7: Estadísticos de F1-score por método de imputación 32
Tabla 8: Rango de F1-score entre imputadores por modelo 34
Tabla 9: Efecto medio de SMOTE sobre las métricas de evaluación 34

ÍNDICE DE FIGURAS

Figura 1: Diagrama explicativo de las múltiples combinaciones entrenadas 16
Figura 2: Matriz de Confusión 25
Figura 3: Ejemplo de una curva ROC 25
Figura 4: Ejemplo de una curva PR 26
Figura 5: Top 20 combinaciones de imputación y modelo según F1-score 29
Figura 6: F1-score medio por tipo de faltantes y método de imputación 29
Figura 7: Evolución del F1-score medio según mecanismo y porcentaje de valores ausentes ... 30
Figura 8: Heatmap del F1-score medio por combinación de mecanismo y porcentaje de valores ausentes 31
Figura 9: Desviación estándar de métricas por método de imputación 32
Figura 10: Distribución de F1-score por método de imputación (boxplot) 32
Figura 11: Comparación de métricas medias por modelo y método de imputación 33
Figura 12: Heatmap de F1-score medio por combinación de modelo e imputador 35
Figura 13: Heatmap de AUC-ROC medio por combinación de modelo e imputador 36
Figura 14: Heatmap de PR AUC medio por combinación de modelo e imputador 36
Figura 15: Radar plot de métricas promedio por método de imputación 37
Figura 16: Radar plot de métricas por combinación de modelo e imputador 37
Figura 17: Correlación entre métricas de evaluación (F1, AUC-ROC, PR AUC) 38

Resumen

Este Trabajo de Fin de Grado tuvo como objetivo comparar diversas técnicas de imputación de datos faltantes aplicadas a grandes bases de datos biomédicas, tomando como caso de estudio el conjunto de datos NHANES. Se evaluaron seis métodos de imputación (media, mediana, kNN, MICE, MissForest y GAIN) combinados con tres modelos de clasificación (k-NN, regresión logística y Random Forest). Se simularon mecanismos de ausencia MCAR, MAR y MNAR, con proporciones del 10 %, 20 % y 30 %. Las combinaciones resultantes fueron evaluadas mediante tres métricas de rendimiento: F1-score, AUC-ROC y PR AUC. El diseño experimental permitió analizar la interacción entre imputación y modelo, el impacto del desbalanceo de clases (a través de SMOTE) y la influencia del tipo y cantidad de datos faltantes. El trabajo incluyó también un análisis visual y cuantitativo de la variabilidad entre métodos, así como un estudio complementario de correlación entre métricas. Los resultados obtenidos han sido sistematizados y presentados mediante tablas, heatmaps, radar plots y rankings globales, proporcionando una visión integral del comportamiento de cada método. La estructura del estudio ha permitido identificar patrones útiles y formular propuestas de mejora metodológica orientadas a estudios futuros en el ámbito de la salud.

Abstract

This Final Degree Project aimed to compare different missing data imputation techniques applied to large biomedical databases, taking the NHANES dataset as a case study. Six imputation methods (mean, median, kNN, MICE, MissForest and GAIN) combined with three classification models (k-NN, logistic regression and Random Forest) were evaluated. MCAR, MAR and MNAR absence mechanisms were simulated, with proportions of 10 %, 20 % and 30 %. The resulting combinations were evaluated using three performance metrics: F1-score, AUC-ROC and PR AUC. The experimental design allowed us to analyse the interaction between imputation and model, the impact of class imbalance (through SMOTE) and the influence of the type and amount of missing data. The work also included a visual and quantitative analysis of the variability between methods, as well as a complementary study of correlation between metrics. The results obtained have been systematised and presented in tables, heatmaps, radar plots and global rankings, providing a comprehensive view of the behaviour of each method. The structure of the study has made it possible to identify useful patterns and formulate proposals for methodological improvement aimed at future studies in the field of health.

1. Introducción

1.1. La problemática de los valores faltantes

La presencia de **valores faltantes** constituye uno de los problemas más frecuentes y relevantes en el análisis de datos reales. Lejos de ser una rareza o un simple inconveniente técnico, la aparición de datos ausentes es una característica inherente a la gran mayoría de los conjuntos de datos recogidos en contextos reales, especialmente en aquellos vinculados a la salud, donde las razones para la ausencia pueden ser de índole técnica, administrativa, económica, o incluso ética.

Desde un punto de vista estadístico, los valores perdidos afectan tanto a la validez interna como externa de los modelos construidos a partir de esos datos. Su presencia puede reducir el tamaño efectivo de la muestra, introducir sesgos en las estimaciones, alterar las correlaciones entre variables o limitar la generalización de los resultados. Todo ello compromete la calidad de las inferencias y decisiones que se tomen sobre dichos modelos (Rubin, 1976).

El manejo adecuado de los valores ausentes requiere, por tanto, una comprensión profunda de sus causas, de su naturaleza probabilística, y de las estrategias disponibles para tratarlos. Entre ellas, la **imputación** —entendida como la estimación y sustitución de los valores faltantes a partir de los observados— se ha consolidado como una técnica estándar, ampliamente utilizada en análisis estadístico, *machine learning* y ciencia de datos aplicada.

La elección del método de imputación adecuado no es trivial. Diferentes algoritmos pueden generar *datasets* imputados que, si bien se parecen superficialmente, inducen modelos muy distintos en términos de predicción o interpretación. Esta variabilidad metodológica hace necesario realizar estudios comparativos sólidos que permitan establecer recomendaciones claras sobre qué método aplicar en función del tipo de ausencia, la proporción de valores perdidos, la naturaleza de las variables y el objetivo del análisis (Schafer & Graham, 2002; Batista & Monard, 2003).

1.2. Motivación del trabajo

La motivación de este trabajo se asienta sobre tres pilares fundamentales. En primer lugar, el reconocimiento de que los valores faltantes no solo son omnipresentes en los datos biomédicos, sino que además se comportan de forma no aleatoria en muchos casos. Mecanismos como **MAR** (Missing At Random) o **MNAR** (Missing Not At Random) son habituales en contextos sanitarios, donde ciertos colectivos son menos propensos a responder a determinadas preguntas o a someterse a ciertas pruebas (Enders, 2010; Schafer & Graham, 2002). Además, en contextos reales, las decisiones sobre cómo manejar los valores perdidos deben equilibrar precisión, coste computacional y aplicabilidad, más allá de la teoría estadística idealizada (Graham, 2009).

En segundo lugar, existe una clara necesidad de aplicar los conocimientos adquiridos durante el Grado en Estadística a un problema real y complejo, donde confluyen técnicas de imputación, algoritmos de clasificación, criterios de validación cruzada y análisis empírico riguroso. Este trabajo representa una oportunidad para integrar herramientas estadísticas y computacionales en un marco aplicado de interés social.

Por último, la elección del dataset **NHANES** como base del estudio aporta un contexto realista, amplio y heterogéneo. Su riqueza variable, su dimensión moderada y su presencia natural de valores perdidos lo convierten en un entorno ideal para evaluar la robustez y utilidad práctica de distintas técnicas de imputación, no de forma teórica, sino en términos del impacto que tienen sobre modelos de clasificación en salud.

1.3. Objetivos

El objetivo general de este Trabajo de Fin de Grado es **evaluar comparativamente distintos métodos de imputación de valores faltantes en bases de datos biomédicas**, analizando su impacto sobre el rendimiento de modelos de clasificación binaria aplicados a la predicción de enfermedades.

De este objetivo general se derivan los siguientes objetivos específicos:

- Describir los tipos de mecanismos de ausencia (**MCAR**, **MAR**, **MNAR**) y sus implicaciones estadísticas.
- Revisar críticamente las principales técnicas de imputación, desde métodos simples hasta algoritmos avanzados.
- Implementar seis métodos de imputación (*media*, *mediana*, *kNN*, *MICE*, *MissForest*, *GAIN*) sobre un conjunto de datos biomédicos reales.
- Evaluar el rendimiento de tres modelos de clasificación (*Random Forest*, *KNN* y *regresión logística*) entrenados sobre datasets imputados.
- Simular artificialmente faltantes bajo distintos mecanismos y proporciones (**10 %**, **20 %**, **30 %**) para analizar la robustez de las técnicas.
- Utilizar métricas como *F1-score*, *ROC AUC* y *PR AUC* para comparar los resultados de cada combinación imputación-modelo.
- Extraer conclusiones prácticas sobre la idoneidad relativa de cada método según el tipo de ausencia, la proporción de *NA* y el modelo utilizado.

1.4. Metodología general del estudio

Este trabajo se desarrolla en dos fases experimentales, aplicadas sobre un conjunto de datos reales (NHANES) previamente depurado.

En la primera fase, se parte del dataset limpio con los valores ausentes que presenta de forma natural. Sobre él se aplican los seis métodos de imputación seleccionados, y posteriormente se evalúa el rendimiento de los modelos de clasificación generados.

En la segunda fase, se introducen de forma controlada valores faltantes artificiales en el mismo dataset, simulando tres mecanismos de ausencia (MCAR, MAR y MNAR) y tres niveles de intensidad (10 %, 20 % y 30 %). A cada uno de estos nuevos datasets se le aplica el mismo pipeline de imputación y evaluación que en la fase anterior.

La calidad de las imputaciones se evalúa indirectamente, mediante el rendimiento de los modelos resultantes. Se utilizan para ello tres métricas estándar: F1-score, AUC-ROC y PR AUC, todas centradas en la clase positiva (diabetes).

1.5. Estructura del trabajo

El presente trabajo se organiza en seis capítulos:

- En el **Capítulo 1**, se presenta el problema abordado, la motivación del estudio, los objetivos perseguidos y la metodología general empleada.
- El **Capítulo 2** desarrolla el marco teórico. Se explican los tipos de ausencia, las técnicas de imputación, las métricas de evaluación y los antecedentes científicos.
- En el **Capítulo 3**, se describe el diseño experimental: dataset utilizado, limpieza de variables, simulación de faltantes, configuración de algoritmos y entorno de análisis.
- El **Capítulo 4** presenta los resultados obtenidos, con tablas comparativas, gráficos y visualizaciones.
- El **Capítulo 5** discute los resultados, identifica patrones, analiza limitaciones y propone interpretaciones y líneas futuras.
- Finalmente, el **Capítulo 6** recoge las conclusiones principales del trabajo.

2. Marco teórico y estado del arte

2.1. Tipos de mecanismos de ausencia

En el análisis estadístico de bases de datos reales, es habitual enfrentarse a observaciones incompletas, donde una o varias variables presentan valores faltantes. Para poder tratar este problema de forma rigurosa, es necesario entender por qué se produce dicha ausencia. La clasificación más ampliamente aceptada de los mecanismos que generan valores faltantes fue propuesta por Rubin (Rubin, 1976), y distingue tres grandes categorías: datos faltantes completamente al azar (MCAR), al azar (MAR) y no al azar (MNAR). Esta tipología tiene implicaciones estadísticas directas, ya que determina la validez de muchos métodos de imputación y análisis posteriores.

Desde el punto de vista formal, sea Y una variable que puede presentar datos faltantes, X el conjunto de variables observadas, y R una variable indicadora de ausencia definida como:

$$\boldsymbol{R} = \begin{cases} \mathbf{1}, & \textbf{\textit{si el valor de Y está observado}} \\ \mathbf{0}, & \textbf{\textit{si el valor de Y está ausente}} \end{cases}$$

La probabilidad condicional $\boldsymbol{P(R = 1 \mid Y, X)}$ describe la forma en la que la presencia de datos está relacionada con los valores observados y no observados. En base a esta expresión, se definen los siguientes mecanismos:

1) **MCAR (Missing Completely At Random)**

Este mecanismo se cumple si la probabilidad de que un valor esté ausente es completamente independiente tanto de las variables observadas como de las no observadas:

$$\boldsymbol{P(R = 1 \mid Y, X) = P(R = 1)}$$

En este caso, los datos faltan por un proceso aleatorio externo al sistema observado. Por tanto, el subconjunto de observaciones completas constituye una muestra aleatoria del total, y los análisis realizados sobre esos datos no están sesgados (aunque pueden ser menos eficientes). Este supuesto es el más fuerte y, paradójicamente, el menos frecuente en la práctica. Un ejemplo sería que un analista olvide introducir aleatoriamente algunos registros en la base de datos, sin patrón alguno.

2) **MAR (Missing At Random)**

El mecanismo MAR se cumple cuando la probabilidad de ausencia depende de las variables observadas, pero no del valor ausente en sí:

$$\boldsymbol{P(R = 1 \mid Y, X) = P(R = 1 \mid X)}$$

Es decir, existe cierta estructura explicativa en los datos observados que justifica los valores perdidos. Este supuesto es más realista que MCAR y permite el uso de técnicas de imputación multivariantes como MICE o MissForest, siempre que las variables relevantes estén incluidas

en el análisis. Por ejemplo, si los pacientes mayores son menos propensos a declarar su nivel de actividad física, y la edad está registrada, la ausencia puede modelarse condicional a ella. Aunque el valor faltante tiene estructura, ésta puede inferirse a partir de las variables observadas.

3) **MNAR (Missing Not At Random)**

En este caso, la probabilidad de ausencia depende directamente del valor faltante:

$$\boldsymbol{P(R = 1 \mid Y, X)\ depende\ de\ Y}$$

Esto implica que, incluso conociendo todas las demás variables, la causa de la ausencia está ligada al valor no observado. Este es el escenario más problemático desde el punto de vista estadístico, ya que no se puede imputar ni modelar el dato sin hacer suposiciones adicionales. Por ejemplo, una persona con un índice de masa corporal extremadamente alto podría decidir no declararlo en una encuesta por motivos personales. Como el valor faltante está relacionado con su propia magnitud, la imputación requiere modelos específicos o enfoques bayesianos con información externa.

2.1.1. Dificultades prácticas para identificar el mecanismo

Determinar el mecanismo que está generando los valores faltantes no es una tarea trivial. Si bien existen pruebas estadísticas como el test de Little para contrastar la hipótesis MCAR, no existe una forma directa de distinguir entre MAR y MNAR con los datos observados. Esto obliga a los analistas a realizar un diagnóstico cuidadoso, estudiar patrones de ausencia y aplicar criterios de plausibilidad.

En muchos trabajos, especialmente en contextos biomédicos, se parte de la hipótesis MAR como un compromiso razonable entre realismo y tratabilidad estadística. Esta suposición permite el uso de modelos avanzados que explotan las relaciones multivariantes del conjunto de datos. Sin embargo, es importante entender que, si en realidad el mecanismo es MNAR, estas técnicas pueden introducir sesgos relevantes (Little & Rubin, 2002).

2.1.2. Aplicación práctica en este trabajo

En el presente estudio, los valores faltantes originales del dataset NHANES se asumen como MAR, dado que muchos de ellos están asociados a patrones observables (como edad, sexo o nivel educativo). Además, con el objetivo de evaluar el comportamiento de las técnicas de imputación en escenarios controlados, se han generado artificialmente valores ausentes bajo los tres mecanismos descritos, en diferentes proporciones (10 %, 20 %, 30 %). Esta simulación controlada permite medir la robustez de cada imputador bajo condiciones progresivamente más adversas, proporcionando una comparación más completa y realista.

2.2. *Técnicas de imputación de valores faltantes*

Existen múltiples estrategias para abordar los valores ausentes en un conjunto de datos. La imputación, en particular, busca reemplazar los valores perdidos por estimaciones plausibles, de forma que se pueda realizar análisis posterior como si el conjunto estuviera completo. No todas las técnicas tienen el mismo nivel de complejidad, ni responden igual de bien ante distintos mecanismos de ausencia, proporciones de valores faltantes o estructuras internas de los datos. Estas técnicas pueden clasificarse de distintas maneras, pero en este trabajo se presentan agrupadas según el tipo de lógica estadística que utilizan (García-Laencina et al., 2010). A continuación, se presentan las principales técnicas empleadas en este trabajo, ordenadas de menor a mayor complejidad, desde métodos univariados simples hasta aproximaciones basadas en aprendizaje profundo.

2.2.1. Imputación por la media, mediana y moda

Estas técnicas simples operan de forma univariada, es decir, rellenan los valores ausentes de una variable utilizando exclusivamente información de esa misma variable. La más habitual en variables numéricas es la imputación por la **media**:

$$\hat{y}_i = \bar{y} = \frac{1}{n}\sum_{j=1} y_j$$

donde y_j son los valores no ausentes de la variable. Si la variable es ordinal o presenta asimetrías importantes, es preferible la **mediana**, que es más robusta a outliers. Para variables categóricas, se utiliza la **moda** (la categoría más frecuente). Estas técnicas son computacionalmente eficientes, pero tienen desventajas claras:

- Ignoran cualquier relación con otras variables.
- Introducen sesgo si los datos no están MCAR.
- Subestiman la varianza de la variable imputada.
- Distorsionan la distribución de los datos (refuerzan valores centrales) (Allison, 2002).

Aun así, siguen siendo útiles como “baseline” o referencia simple en estudios comparativos, como es el caso en este trabajo.

2.2.2. k-Nearest Neighbors (kNN)

La imputación basada en vecinos cercanos es una técnica no paramétrica que toma ventaja de la estructura multivariada del dataset. Para cada observación incompleta, se busca el subconjunto de k registros más similares (los “vecinos”) según una métrica de distancia definida sobre las variables disponibles. El valor imputado es una función agregada de los vecinos: media en variables continuas, moda en categóricas.

$$\hat{y}_i = \frac{1}{k}\sum_{j=V(i)} y_j$$

donde $\boldsymbol{V(i)}$ es el conjunto de índices de los $\boldsymbol{k}$ vecinos más cercanos a la observación i.

Este enfoque no requiere supuestos paramétricos y permite capturar patrones locales no lineales. Sin embargo, su rendimiento depende de la elección de $\boldsymbol{k}$, de la escala de las variables (requiere normalización previa), y puede verse afectado por outliers y datos ruidosos (Hastie et al., 2009). Tiene además un coste computacional elevado en datasets grandes.

kNN suele funcionar mejor en datasets con estructura densa y correlaciones locales fuertes, y ha sido ampliamente utilizado en estudios biomédicos como la imputación de microarrays (Troyanskaya et al., 2001).

2.2.3. Métodos basados en modelos (MICE, MissForest, etc.)

Los métodos basados en modelos asumen que las variables observadas en un conjunto de datos pueden usarse para predecir aquellas que presentan valores ausentes. Esta aproximación explota la estructura condicional del conjunto, en lugar de tratar cada variable de forma aislada. Son especialmente útiles bajo el supuesto MAR (Missing At Random), en el que la ausencia depende de variables observadas. Dentro de esta familia se incluyen tanto estrategias paramétricas como no paramétricas. Este trabajo emplea dos de las más representativas: **MICE**, que construye modelos condicionales encadenados, y **MissForest**, que utiliza bosques aleatorios entrenados de forma iterativa.

*2.2.3.1. Imputación múltiple por ecuaciones encadenadas (**MICE**)*

MICE (Multiple Imputation by Chained Equations) construye un sistema de modelos univariados condicionales que se ajustan de manera secuencial. Su objetivo es generar varios conjuntos completos de datos, capturando la incertidumbre asociada al proceso de imputación.

Sea $\boldsymbol{Y} = (\boldsymbol{Y^{(obs)}},\ \boldsymbol{Y^{(miss)}})$ el conjunto de datos dividido en observados y ausentes. MICE parte de una inicialización simple de $\boldsymbol{Y^{(miss)}}$ y luego, para cada variable $\boldsymbol{Y_j}$ con datos ausentes, estima un modelo condicional:

$$\boldsymbol{Y_j^{(mis)}} \sim \boldsymbol{P(Y_j \mid Y_{-j})}$$

donde $\boldsymbol{Y_{-j}}$ son las demás variables. El proceso se repite en ciclos hasta alcanzar convergencia. Tras repetirlo mmm veces, se obtienen mmm datasets completos, cuya variabilidad refleja la incertidumbre de la imputación. Cada conjunto se analiza por separado y los resultados se combinan con las reglas de Rubin para obtener una estimación agregada del parámetro de interés Q:

$$\boldsymbol{\bar{Q}} = \frac{\boldsymbol{1}}{\boldsymbol{m}} \sum_{\boldsymbol{i=1}}^{\boldsymbol{m}} \boldsymbol{Q_i}\,, \qquad \boldsymbol{T} = \boldsymbol{\bar{U}} + \left(\boldsymbol{1} + \frac{\boldsymbol{1}}{\boldsymbol{m}}\right)\boldsymbol{B}$$

donde $\boldsymbol{\bar{U}}$ es la media de las varianzas internas y $\boldsymbol{B}$ la varianza entre imputaciones.

El atractivo de MICE reside en su flexibilidad: puede aplicar regresiones lineales, logísticas o multinomiales según el tipo de variable, y permite adaptar cada modelo de forma independiente (van Buuren & Groothuis-Oudshoorn, 2011). Su éxito en contextos biomédicos es ampliamente documentado (Azur et al., 2011).

2.2.3.2. *Imputación iterativa con bosques aleatorios (**MissForest**)*

MissForest es un algoritmo no paramétrico que se basa en la capacidad de los Random Forests para capturar relaciones complejas, no lineales y de interacción entre variables. A diferencia de MICE, MissForest genera una única imputación determinista o estocástica, pero aprovecha el conjunto completo de covariables en cada paso.

El procedimiento se puede resumir así:

1. Inicializar $\boldsymbol{Y}^{(\boldsymbol{miss})}$ con valores simples (media o moda).
2. Ordenar las variables por proporción de NA.
3. Para cada variable $\boldsymbol{Y_j}$ con NA, entrenar un Random Forest $\boldsymbol{f_j}$ con las demás variables $\boldsymbol{Y_{-j}}$.
4. Imputar:

$$\widehat{\boldsymbol{Y}}_{\boldsymbol{j}}^{(\boldsymbol{obs})} = \boldsymbol{f_j}\left(\boldsymbol{Y}_{-\boldsymbol{j}}^{(\boldsymbol{obs})}\right)$$

5. Repetir el ciclo completo hasta que el error converge (por ejemplo, cuando la diferencia entre imputaciones sucesivas es menor que un umbral δ).

Este método permite imputar de forma conjunta variables numéricas y categóricas, sin necesidad de normalización ni codificación. Además, al no requerir suposiciones sobre la distribución de los datos, es robusto frente a outliers y a relaciones no lineales entre variables (Stekhoven & Bühlmann, 2012).

En estudios comparativos, MissForest ha superado a métodos como kNN o imputación media en escenarios mixtos, especialmente cuando los patrones de ausencia afectan a múltiples variables con interacciones cruzadas. Aunque no proporciona múltiples datasets imputados como MICE, su estabilidad y su precisión lo convierten en una opción sólida en aplicaciones predictivas donde no se requiere inferencia formal.

2.2.4. <u>Métodos basados en aprendizaje profundo (Autoencoders, GAIN, MIDAS)</u>

La reciente incorporación de arquitecturas de deep learning al campo de la imputación ha supuesto un cambio de paradigma respecto a los métodos estadísticos tradicionales. Estos modelos no requieren una especificación explícita de la relación entre variables, sino que aprenden directamente la estructura multivariada del dato a partir de sus representaciones latentes. Algunos de los enfoques más representativos en este campo son los **autoencoders**, las arquitecturas con mecanismos de atención como **MIDAS**, y los modelos generativos como **GAIN**.

Los autoencoders son redes neuronales entrenadas para reconstruir su entrada a partir de una codificación comprimida. Aunque pueden imputar valores ausentes tratando los datos incompletos como entradas parcialmente observadas, su rendimiento depende en gran medida del tamaño del dataset, la normalización previa y el "tuning" de **hiperparámetros** (Gondara & Wang, 2018). Por su parte, MIDAS es una arquitectura más reciente que emplea autoencoders con mecanismos de atención y enmascaramiento dinámico, orientada especialmente a series temporales (Lu et al., 2020). Su uso en contextos biomédicos generales es aún limitado, pero apunta hacia líneas futuras prometedoras.

Entre todos los métodos mencionados, GAIN (Generative Adversarial Imputation Nets) destaca como uno de los más estudiados y generalizables. Fue propuesto por Yoon et al. (2018) y representa un enfoque completamente distinto a los métodos anteriores: en lugar de ajustar modelos estadísticos explícitos o explotar vecindad, GAIN entrena un generador para crear imputaciones realistas y un discriminador que trata de distinguirlas de los valores reales.

Su arquitectura incluye:

- Un generador $\boldsymbol{G}(\boldsymbol{Z}, \boldsymbol{M})$, que toma como entrada una máscara $\boldsymbol{M}$ (que indica qué valores están ausentes) y una variable ruidosa $\boldsymbol{Z}$, para producir valores imputados.
- Un discriminador $\boldsymbol{D}(\boldsymbol{X}, \boldsymbol{H})$, que recibe como entrada el dataset parcialmente observado y una pista adicional $\boldsymbol{H}$ (que ayuda a estabilizar el entrenamiento), y predice si un valor es real o imputado.

La función objetivo general incluye dos términos:

- Una pérdida adversarial, que fuerza al generador a producir imputaciones indistinguibles de los datos reales.
- Una pérdida de reconstrucción, que penaliza grandes diferencias entre valores reales y generados, solo donde hay datos conocidos.

La combinación de ambas permite que el modelo aprenda distribuciones complejas sin necesidad de hipótesis paramétricas. La idea central es que, si el generador engaña consistentemente al discriminador, entonces las imputaciones son plausibles según la distribución real del dato.

Este enfoque tiene varias ventajas:

- Captura relaciones multivariadas complejas.
- Produce imputaciones coherentes a nivel global.
- Puede funcionar bien incluso bajo MNAR.

Y también limitaciones:

- Su entrenamiento es inestable (problema común en GANs).
- Requiere mayor número de parámetros y ajustes.
- La interpretabilidad es muy baja.

- Necesita mayor potencia computacional que otros métodos.

En este trabajo, GAIN se incluye como representante de las técnicas modernas basadas en deep learning. Si bien su implementación es más exigente, sus resultados permiten evaluar si el coste computacional se traduce en un aumento efectivo del rendimiento predictivo.

2.2.5. Imputación en variables categóricas: carencias y propuestas recientes

Las variables categóricas plantean retos particulares en imputación, ya que muchos algoritmos clásicos están pensados para datos numéricos. Una solución común es reemplazar los valores ausentes por la categoría más frecuente (**moda**), pero esta estrategia tiende a reforzar el sesgo hacia clases mayoritarias, reduciendo la variabilidad y deteriorando la distribución real de la variable (García-Laencina et al., 2010).

Entre los métodos más extendidos, k-NN puede aplicarse a variables cualitativas, pero requiere transformar previamente los datos con técnicas como Label Encoding o **One-Hot Encodin**g, que convierten las categorías en valores numéricos. Este paso puede introducir redundancia o relaciones artificiales entre categorías que no tienen un orden lógico, distorsionando el análisis posterior.

En este trabajo, se han empleado dos métodos que evitan esas transformaciones y manejan directamente variables categóricas: MICE y MissForest. MICE permite modelar variables cualitativas mediante regresión logística o multinomial, manteniendo coherencia con las covariables observadas. MissForest, por su parte, maneja tanto variables numéricas como categóricas de forma nativa gracias a su base en árboles de decisión aleatorios, sin necesidad de codificación previa.

Ambos métodos han demostrado resultados robustos en entornos biomédicos y se adaptan bien a conjuntos de datos con tipologías mixtas. Su uso garantiza imputaciones coherentes y menos sesgadas, preservando tanto la estructura multivariada como la diversidad categórica original.

2.3. Impacto de la imputación en modelos de machine learning

La imputación de valores faltantes no es una tarea aislada: tiene consecuencias directas en el rendimiento, la estabilidad y la interpretabilidad de los modelos de machine learning que se entrenan posteriormente. Su influencia depende del tipo de algoritmo utilizado, del mecanismo que generó las ausencias y del método de imputación aplicado. En escenarios reales, el éxito de un sistema predictivo depende tanto del modelo como de la calidad de los datos imputados.

Desde un punto de vista teórico, imputar equivale a completar el espacio de características con estimaciones basadas en supuestos. Cuando estos supuestos son erróneos, se introducen sesgos sistemáticos que alteran la distribución de los datos y comprometen la validez de los modelos posteriores. Por ejemplo, imputar por la media puede reducir artificialmente la

varianza de una variable y aplanar correlaciones multivariadas, afectando a modelos sensibles a la dispersión como **k-NN** o **PCA** (Enders, 2010).

En algoritmos como regresión logística o redes neuronales, la imputación puede desplazar el hiperplano de decisión si las imputaciones no son representativas del mecanismo real de generación de datos. En modelos como los árboles de decisión o Random Forests, la situación es más matizada: algunos algoritmos pueden tratar valores faltantes de forma interna (por ejemplo, mediante divisiones subrogadas), mientras que otros requieren una imputación previa. En cualquier caso, el modo en que se imputa afecta a las reglas aprendidas por el modelo y, por tanto, a su **comportamiento predictivo**.

Uno de los aspectos más relevantes es el "**overfitting**" inducido por la imputación. Cuando se rellenan los valores perdidos con estimaciones excesivamente optimistas (por ejemplo, mediante regresión perfectamente ajustada a los datos conocidos), el modelo posterior puede aprender patrones artificialmente consistentes, que no se sostienen en nuevas observaciones. Esto se agrava si se imputan valores de test con información de train (**data leakage**), o si no se respeta adecuadamente la separación entre fases de entrenamiento y evaluación.

Además, la imputación puede afectar a la **interpretabilidad** de los modelos. Por ejemplo, si se utilizan técnicas de imputación que alteran la relación entre variables (como autoencoders o GANs), las explicaciones basadas en importancia de variables pueden no reflejar la estructura original del dataset. En tareas clínicas o epidemiológicas, donde la trazabilidad del razonamiento es clave, esta falta de interpretabilidad puede limitar la adopción de modelos complejos.

Otro aspecto clave es la **robustez del modelo** frente a variaciones en las imputaciones. Métodos como *MissForest* o *GAIN* introducen cierto grado de aleatoriedad, lo que puede generar modelos distintos según la semilla inicial. En esos casos, evaluar la **estabilidad del modelo** (por ejemplo, mediante múltiples repeticiones con distintas imputaciones) resulta crucial para obtener conclusiones fiables.

Por todo lo anterior, evaluar el impacto de los métodos de imputación no debe limitarse a medir el error de imputación directo (como RMSE o MAE), sino que debe incluir métricas posteriores al modelado, como AUC, F1-score o precision-recall, en distintos algoritmos. Esta evaluación indirecta permite comprobar si una técnica de imputación no solo aproxima bien los valores perdidos, sino que además preserva la capacidad predictiva del sistema completo (Saar-Tsechansky & Provost, 2007).

En este trabajo se comparan varios métodos de imputación bajo distintos mecanismos de ausencia (MCAR, MAR, MNAR), y se evalúa cómo influyen en modelos de clasificación entrenados con **k-NN**, **regresión logística** y **Random Forest**. Esta aproximación permite estudiar no solo la precisión individual de cada técnica, sino también su interacción con los modelos y su estabilidad general.

2.4. *Evaluación de imputación en la literatura: métricas y criterios*

Evaluar la calidad de un proceso de imputación es esencial para determinar si las estimaciones de los valores faltantes son razonables y si preservan la estructura estadística del conjunto de datos original. La literatura ha propuesto distintas estrategias de evaluación que pueden agruparse en dos categorías principales: **métricas directas**, que comparan los valores imputados con los verdaderos cuando se conocen; y **métricas indirectas**, que evalúan el rendimiento de modelos predictivos entrenados sobre los datos imputados. A estas se suman otros criterios complementarios como la estabilidad del método, la interpretabilidad del resultado final y el **coste computacional** asociado.

2.4.1. Métricas directas (RMSE, MAE, etc.)

Cuando es posible comparar los valores imputados con los valores reales (por ejemplo, en estudios simulados donde se eliminan valores artificialmente), se emplean métricas como el **error cuadrático medio (RMSE)** o el **error absoluto medio (MAE)**:

$$RMSE = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(x_i - \hat{x}_i)^2}, \qquad MAE = \frac{1}{n}\sum_{i=1}^{n}|x_i - \hat{x}_i|$$

Estas métricas miden cuánto se aleja el valor imputado del valor real, penalizando de forma distinta los errores grandes. El RMSE es más sensible a outliers, mientras que el MAE ofrece una medida más robusta. En el caso de variables categóricas, se suelen utilizar tasa de error de clasificación o índice de coincidencia.

Este tipo de evaluación es útil cuando se conoce el "**ground truth**", pero presenta limitaciones en contextos reales donde los valores verdaderos faltantes no están disponibles.

2.4.2. Métricas indirectas (AUC, accuracy posterior a la imputación)

En escenarios aplicados, la calidad de la imputación se mide indirectamente a través del rendimiento de modelos predictivos entrenados sobre los datos completados. El supuesto es que una buena imputación debe permitir entrenar modelos que generalicen bien. Entre las métricas habituales destacan:

- **Accuracy**: proporción de clasificaciones correctas.
- **F1-score**: media armónica entre precisión y exhaustividad, útil en datasets desbalanceados.
- **AUC (Área bajo la curva ROC)**: mide la capacidad de discriminación del modelo entre clases.
- **Precision-Recall AUC**: especialmente relevante cuando hay clases minoritarias.

Estas métricas permiten evaluar si la imputación ha preservado las relaciones entre variables y la señal predictiva presente en los datos. En este enfoque, la imputación se juzga no por su similitud con los valores reales, sino por su utilidad en tareas posteriores.

2.4.3. Estabilidad, interpretabilidad y coste computacional

Además del rendimiento, la literatura también valora criterios complementarios que afectan a la **fiabilidad y aplicabilidad** de los métodos de imputación.

1) **Estabilidad**: se refiere a la variabilidad de los resultados al aplicar el método múltiples veces con semillas distintas o ligeras variaciones en los datos. Métodos como MissForest o GAIN pueden producir imputaciones distintas entre ejecuciones, lo que afecta a la reproducibilidad. Evaluar la desviación estándar de las métricas predictivas entre repeticiones permite cuantificar esta estabilidad.
2) **Interpretabilidad**: algunos métodos (como la imputación por media o MICE) permiten entender con claridad cómo se ha imputado cada valor. Otros, como los autoencoders o GAIN, actúan como cajas negras, lo que puede ser problemático en contextos médicos o regulatorios.
3) **Coste computacional**: la imputación debe ser razonablemente eficiente en tiempo y recursos. MissForest y GAIN, por ejemplo, requieren más tiempo y memoria que métodos simples o k-NN. En estudios con múltiples repeticiones y datasets grandes, este coste puede limitar la viabilidad práctica.

En conjunto, la evaluación completa de un método de imputación debe considerar no solo su precisión en recuperar valores ausentes, sino también su efecto en tareas de modelado, su reproducibilidad y sus requisitos computacionales. Este enfoque integral es el adoptado en el presente trabajo para comparar las distintas estrategias implementadas.

2.5. Benchmarks anteriores y trabajos relevantes

Durante los últimos años, diversos estudios han evaluado sistemáticamente la eficacia de los métodos de imputación en múltiples contextos. Estos análisis comparativos, conocidos como benchmarks, permiten contrastar técnicas bajo condiciones controladas y guiar su uso según las características del problema.

Uno de los trabajos más destacados en este sentido es el de **Jäger et al. (2021)**, publicado en "Frontiers in Big Data", donde se comparan 11 métodos de imputación aplicados a 15 conjuntos de datos reales, incluyendo dominios biomédicos, financieros y sociales. El estudio contempla métricas tanto directas (como RMSE) como indirectas (como accuracy o AUC), y evalúa la robustez de las técnicas bajo distintos mecanismos de ausencia (MCAR, MAR, MNAR).

Entre los métodos analizados se encuentran enfoques simples (media, mediana), métodos basados en vecinos (k-NN), y técnicas modernas como autoencoders y redes generativas (GAIN). Sin embargo, no se incluyen técnicas intermedias muy utilizadas como MICE o MissForest, lo cual ha sido señalado como una limitación parcial, ya que son ampliamente usadas en entornos clínicos y en ciencia de datos aplicada. Este aspecto representa una diferencia importante respecto al presente estudio, donde ambas técnicas sí han sido evaluadas.

Inspirándose en parte en la estructura experimental de Jäger et al., el trabajo actual amplía el enfoque al integrar modelos adicionales y evaluar el impacto de la imputación en tareas de clasificación concretas. De esta manera, se aporta evidencia complementaria centrada en un caso biomédico real, con base en el dataset NHANES.

Otros trabajos relevantes en la literatura también han explorado el efecto de la imputación en el rendimiento de modelos predictivos:

- **Saar-Tsechansky y Provost (2007)** analizaron cómo el tipo de imputación afecta a la capacidad predictiva de modelos supervisados, destacando que la interacción entre imputación y clasificación es tan importante como la técnica en sí.
- **Che et al. (2018)** introdujeron GRU-D, una arquitectura basada en redes recurrentes para imputación de series temporales, subrayando que la elección del método debe adaptarse al tipo de dato (estático, longitudinal, etc.).
- **Twala et al. (2008)** compararon distintos enfoques en el contexto de clasificación, y mostraron que los métodos no paramétricos suelen ofrecer mayor robustez cuando se desconoce la distribución de los datos, lo que respalda el uso de técnicas como MissForest.

En conjunto, estos estudios han consolidado un marco de evaluación plural que va más allá del error de imputación, considerando aspectos como el rendimiento predictivo, la estabilidad y la aplicabilidad práctica. El presente trabajo se inserta en esa línea, con un enfoque específicamente adaptado al ámbito biomédico y a las necesidades reales de imputación en datasets con estructuras complejas.

2.6. Contribución del presente trabajo

A partir del marco teórico revisado, se constata que la imputación de datos faltantes sigue siendo un problema relevante y abierto en ciencia de datos aplicada, especialmente en contextos biomédicos donde las decisiones pueden tener impacto clínico o epidemiológico directo. La literatura ha desarrollado numerosos métodos de imputación, pero persisten dudas sobre su rendimiento relativo bajo distintas condiciones, y **pocos estudios ofrecen comparativas sistemáticas aplicadas a bases de datos reales con estructura compleja y múltiples tipos de variables**.

En este trabajo se aborda esta cuestión mediante un análisis comparativo aplicado al dataset NHANES, ampliamente utilizado en estudios de salud pública. La contribución principal es doble:

- Por un lado, se implementa y compara un conjunto representativo de seis métodos de imputación, incluyendo técnicas simples (media, mediana), modelos clásicos (k-NN, MICE, MissForest) y métodos de última generación como GAIN, cubriendo así una gama amplia de aproximaciones.

- Por otro, se evalúa el efecto de estas técnicas no solo en términos de precisión de imputación, sino también en su impacto sobre el rendimiento de tres modelos de clasificación supervisada (k-NN, regresión logística, Random Forest), bajo condiciones controladas de ausencia (MCAR, MAR, MNAR) y distintos porcentajes de pérdida (10 %, 20 %, 30 %).

Además, el estudio incluye un análisis gráfico detallado, evaluaciones de estabilidad y métricas complementarias, siguiendo los estándares metodológicos propuestos por la literatura reciente.

Con ello, se busca no solo comparar técnicas, sino también ofrecer recomendaciones prácticas sobre qué métodos utilizar en entornos biomédicos reales con restricciones de interpretabilidad, coste computacional o variabilidad estructural.

3. Material y métodos

El análisis desarrollado en este trabajo combina técnicas de procesamiento, imputación y modelado predictivo sobre una base de datos biomédica real. Todo el flujo de trabajo se ha implementado en lenguaje **Python**, utilizando el entorno **Google Colab** por su flexibilidad y su buena integración con librerías avanzadas de ciencia de datos. Para facilitar la gestión de los datos en las distintas fases del estudio, se ha trabajado extensamente con archivos en formato .parquet, que permiten una lectura rápida y eficiente, especialmente útil en procesos iterativos de imputación y validación.

A lo largo del proyecto se han diseñado y ejecutado dos experimentos complementarios sobre el mismo conjunto de datos: uno utilizando la versión original con valores ausentes reales, y otro en el que se han introducido valores faltantes de forma controlada. En ambos casos, se han aplicado distintas técnicas de imputación y, posteriormente, modelos de clasificación supervisada para evaluar su impacto. Este enfoque ha permitido generar un volumen elevado de combinaciones imputación-modelo, cuya comparación se ha estructurado de forma sistemática. El conjunto de experimentos se ha diseñado con el objetivo de explorar no solo el rendimiento individual de cada técnica, sino también su comportamiento relativo bajo distintos escenarios de datos incompletos.

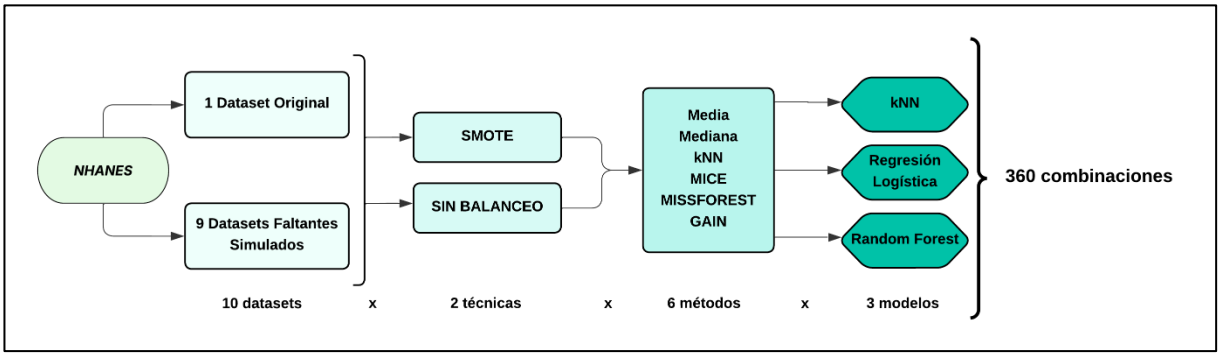

Figura 1: Diagrama explicativo de las múltiples combinaciones entrenadas

3.1. Descripción del dataset NHANES

En este trabajo se ha utilizado el conjunto de datos proporcionado por el paquete NHANES del software estadístico **R** (Wickham, 2025; R Core Team, 2023). Este conjunto es una versión simplificada y reestructurada de los datos recogidos por el programa National Health and Nutrition Examination Survey (NHANES), una encuesta nacional periódica realizada por los Centros para el Control y la Prevención de Enfermedades (CDC) de Estados Unidos (National Center for Health Statistics, 2023). La versión incluida en el paquete de R combina información de los ciclos 2009–2010 y 2011–2012, con aproximadamente **10.000 individuos y 76 variables**.

Este dataset ha sido **preprocesado** para incorporarlo como una librería de R. Se han eliminado variables complejas, se ha reducido el número de individuos y se han eliminado los pesos muestrales, los estratos y los conglomerados que permiten realizar inferencias poblacionales a nivel nacional. En consecuencia, aunque la estructura de los datos es real y

representa una amplia gama de variables clínicas, sociodemográficas y de estilo de vida, los resultados obtenidos en este trabajo no son extrapolables a la población general de EE. UU., y el análisis debe interpretarse como metodológico, no epidemiológico.

La selección de variables ha sido guiada por criterios tanto estadísticos como clínicos, priorizando aquellas con contenido informativo alto, relación potencial con el diagnóstico de **diabetes**, y nivel de completitud aceptable. Tras un proceso exhaustivo de **limpieza** (descrita en la sección siguiente), se han retenido 34 variables que incluyen tanto predictores continuos como categóricos: edad, nivel educativo, presión arterial, consumo de alcohol, glucosa en ayunas, índice de masa corporal (IMC), actividad física, colesterol, niveles de insulina, entre otros. La variable objetivo es la presencia o ausencia de diabetes diagnosticada, determinada a partir de variables clínicas y cuestionarios estandarizados.

VARIABLE	TIPO	DESCRIPCIÓN BREVE
EDAD	Numérica continua	Edad del participante en años.
IMC	Numérica continua	Índice de masa corporal calculado como peso/talla^2.
PRESIÓN SISTÓLICA	Numérica continua	Presión arterial sistólica medida clínicamente.
CONSUMO ALCOHOL	Categórica ordinal	Frecuencia de consumo de bebidas alcohólicas.
NIVEL EDUCATIVO	Categórica ordinal	Nivel máximo de estudios alcanzado.
DIABETES	Binaria	Diagnóstico de diabetes (sí/no) basado en criterio clínico.

Tabla 1: Variables representativas del conjunto de datos NHANES

Una característica importante del dataset NHANES es que los valores faltantes no se deben únicamente a errores aleatorios o pérdidas técnicas, sino también a patrones estructurados derivados del diseño del estudio: no todos los participantes son sometidos a todas las pruebas, algunos ítems se omiten por decisión del encuestado, y ciertos resultados se censuran o se consideran no divulgables. Esta combinación de mecanismos de ausencia MCAR, MAR y MNAR convierte a NHANES en un escenario particularmente realista y desafiante para evaluar métodos de imputación.

Además, muchas variables presentan escalas distintas, rangos heterogéneos y codificaciones múltiples (p.ej., categóricas ordinales, binarias, nominales con decenas de niveles), lo que ha requerido un tratamiento cuidadoso tanto en la etapa de limpieza como en la codificación posterior. En este sentido, NHANES representa un banco de pruebas ideal para comparar algoritmos de imputación en contextos biomédicos complejos y de alta dimensionalidad.

3.2. *Selección de variables y procesamiento inicial*

3.2.1. Limpieza de la base de datos

El conjunto inicial de datos contenía 76 variables procedentes del fichero NHANES.parquet disponible en el Anexo. Dado el objetivo de comparar distintos métodos de imputación sobre un dataset biomédico realista pero manejable, se llevó a cabo un proceso de depuración riguroso, dividido en tres fases consecutivas. Este procedimiento fue implementado en el script "*Limpieza_inicial_dataset_NHANES.ipynb*" (también disponible en el Anexo) y documentado con detalle en los comentarios del código. Las variables fueron descartadas por razones de completitud insuficiente, especificidad excesiva, redundancia, irrelevancia clínica o problemas estructurales.

1) **Primera limpieza:** completitud, especificidad y sensibilidad

La primera depuración se centró en variables con escasa información disponible o aplicabilidad limitada. Se eliminaron 27 variables, dejando el conjunto reducido a 49. Los criterios aplicados fueron:

- Más del 90 % de datos ausentes: variables virtualmente inutilizables desde el punto de vista analítico.
- Variables dirigidas a población infantil o subgrupos minoritarios (p. ej., mujeres embarazadas): alto grado de especificidad y sesgo de representatividad.
- Variables sensibles o privadas con más del 40 % de NA: podrían inducir sesgos éticos o de interpretación.
- Variables administrativas: información ya contenida en otras variables o sin valor predictivo.

Criterio aplicado	Variables eliminadas (selección representativa)
>90 % de NA	HeadCirc, Length, DiabetesAge, TVHrsDayChild, CompHrsDayChild
Subgrupos específicos (80–90 % NA)	BMICatUnder, PregnantNow, Age1stBaby, AgeRegMarij, UrineVol2, UrineFlow2
Subgrupos demográficos (70–80 % NA)	nBabies, nPregnancies, AgeFirstMarij, SmokeAge
Variables sensibles (>40 % NA)	SexOrientation, SexNumPartYear, AlcoholDay, HardDrugs, SameSex, Testosterone, Race3, AgeMonths, SexAge, SexNumPartnLife, SexEver
Variables administrativas	ID

Tabla 2: Variables eliminadas en la primera limpieza (27 en total)

Esta fase permitió eliminar variables sin potencial predictivo útil, reduciendo la dimensionalidad sin perder información relevante. El dataset resultante quedó

compuesto por 49 variables, con una estructura ya más adaptada a técnicas de imputación multivariantes.

2) **Segunda limpieza:** redundancia estadística y estructura inconsistente

En la segunda fase se eliminaron 12 variables adicionales, principalmente por razones de redundancia, colinealidad o mal ajuste estructural. El conjunto se redujo de 49 a 37 variables. Los criterios empleados fueron:

- Mediciones múltiples de una misma dimensión (presión arterial): alta correlación (>0.95) entre versiones. Mantengo "BPSysAve" y "BPDiaAve".
- Redundancia funcional: variables que miden lo mismo bajo distintos nombres o codificaciones. En los tres tipos de casos mantengo una o dos variables que cubran ese espectro.

Criterio aplicado	Variables eliminadas
Medidas repetidas de presión arterial	BPSys1, BPDia1, BPSys2, BPDia2, BPSys3, BPDia3
Redundancia en variables de tabaquismo	SmokeNow, Smoke100n
Redundancia en variables de ingresos	HHIncomeMid
Redundancia o alta tasa de NA (>50%) en estilo vida	TVHrsDay, CompHrsDay, PhysActiveDays

Tabla 3: Variables eliminadas en la segunda limpieza (12 en total)

Tras esta limpieza, el dataset quedó reducido a 37 variables con buena cobertura, mínima duplicación y coherencia estructural. Se garantizó la presencia de todas las dimensiones clínicas y sociodemográficas relevantes.

3) **Tercera limpieza:** revisión conceptual y optimización final

La tercera y última limpieza tuvo un carácter más cualitativo, eliminando solo tres variables adicionales tras una revisión clínica y metodológica. La decisión se basó en criterios de relevancia predictiva, redundancia final o falta de valor estructural.

Criterio aplicado	Variables eliminadas
Redundancia en marihuana	RegularMarij (Marijuana ya captura el uso)
Alta colinealidad con otra variable	Weight (alta correlación con BMI)
Variable administrativa no predictiva	SurveyYr (50% cada año, no aporta valor predictivo médico)

Tabla 4: Variables eliminadas en la tercera limpieza (3 en total)

Con esta última fase, el conjunto de datos definitivo quedó formado por **34 variables**, balanceadas entre numéricas y categóricas, con una tasa de valores faltantes razonable y estructura apta para técnicas de imputación modernas.

3.2.2. Codificación de variables categóricas

La codificación no se aplicó directamente durante la limpieza, pero sí en las etapas posteriores del pipeline de imputación y modelado. Las estrategias aplicadas fueron:

- **Variables binarias**: codificadas como 0 y 1.
- **Ordinales**: respetando su jerarquía numérica natural.
- **Nominales**: se evitó One-Hot Encoding extensivo por motivos de eficiencia computacional. En su lugar, se aplicó codificación numérica simple mediante *Label Encoding* cuando era necesario.

3.2.3. Estandarización de variables numéricas

Para armonizar la escala de las variables numéricas y mejorar la estabilidad de los algoritmos sensibles a magnitudes (como k-NN o regresión logística), se aplicó la transformación z-score:

$$\boldsymbol{X_{norm} = \frac{X - \mu}{\sigma}}$$

donde $\boldsymbol{\mu}$ y $\boldsymbol{\sigma}$ se calcularon sobre el conjunto de entrenamiento exclusivamente. Esta transformación se ejecutó tras la división train/test, evitando fugas de información.

Con este proceso de limpieza, codificación y estandarización, el conjunto de datos NHANES quedó listo para ser sometido a los distintos métodos de imputación seleccionados, garantizando condiciones homogéneas de entrada y compatibilidad estructural con los algoritmos empleados. La coherencia del preprocesamiento constituye una etapa clave para evaluar de forma justa el impacto de cada técnica de imputación sobre el rendimiento predictivo posterior.

3.3. Variable objetivo y tipo de tarea

La variable-objetivo seleccionada para el estudio es **Diabetes**, que recoge la respuesta a la siguiente pregunta formulada en los cuestionarios del NHANES: *"Have you ever been told by a doctor or other health professional that you have diabetes?"*. Se trata, por tanto, de un indicador autodeclarado de la enfermedad, basado en la percepción y el recuerdo del encuestado, y no en criterios clínicos objetivos como la medición directa de glucosa en sangre o los niveles de hemoglobina glicosilada (HbA1c).

Esta característica implica una limitación relevante: no es posible confirmar con precisión la presencia o ausencia real de la diabetes, lo que introduce cierta incertidumbre en la definición de la clase positiva. Sin embargo, en el contexto de este trabajo, dicha limitación se considera aceptable y manejable, ya que el objetivo central no es evaluar el diagnóstico clínico en sí, sino comparar el efecto de distintas técnicas de imputación de valores faltantes sobre el rendimiento de modelos predictivos. En ese sentido, la variable *Diabetes* proporciona un criterio suficientemente razonable para definir una tarea de clasificación binaria con aplicabilidad práctica.

Para facilitar el análisis, se construyó una versión binarizada de esta variable, denominada *Diabetes_bin*, en la que se codificaron como 1 las respuestas "Yes" (es decir, individuos que reportaron haber sido diagnosticados con diabetes), y como 0 las respuestas "No". Se excluyeron explícitamente del análisis aquellas observaciones con respuestas ambiguas como "Don't know", "Refused", o con valores directamente perdidos. Esta depuración garantiza una definición clara de las clases y evita introducir ruido o inconsistencias en el conjunto de datos.

El tipo de tarea planteado es, por tanto, una **clasificación supervisada binaria**, en la que se busca predecir la presencia de diabetes a partir de un conjunto de variables biomédicas, sociodemográficas y conductuales. Esta configuración resulta adecuada para evaluar cómo influye la calidad de la imputación en la capacidad de los modelos de machine learning para identificar correctamente a los individuos diabéticos, simulando un escenario de aplicación real en salud pública o medicina preventiva.

3.4. Simulación controlada de valores faltantes

Con el fin de analizar el comportamiento de los métodos de imputación bajo condiciones controladas, se desarrolló una segunda fase experimental centrada en la introducción artificial de valores faltantes sobre el dataset original ya limpio. Este proceso permitió simular distintos escenarios de ausencia, basados en criterios explícitos y replicables. La generación se realizó en Python mediante el script accesible en el Anexo: "*Generador_Datasets_FaltantesSimulados.ipynb*", dando lugar a nueve nuevos datasets, resultado de cruzar tres mecanismos de ausencia (MCAR, MAR y MNAR) con tres niveles de intensidad (10 %, 20 % y 30 %).

Antes de aplicar los mecanismos, se entrenó un modelo de **Random Forest Classifier** sobre el conjunto completo con codificación OneHot para las variables categóricas, y se calcularon las importancias de cada variable. A partir de este análisis se seleccionaron las 15 variables más influyentes en la predicción de la diabetes, y solo en esas se introdujeron valores faltantes en los experimentos simulados. Esta estrategia garantiza que las ausencias afecten a variables realmente relevantes desde el punto de vista predictivo, aumentando el realismo del escenario y la dificultad de la imputación.

1) **MCAR (Missing Completely At Random)**

En el caso MCAR, los valores faltantes se introdujeron de forma completamente aleatoria sobre el conjunto total de observaciones, sin depender de ninguna característica del individuo ni del valor original. La asignación se aplicó de forma uniforme a las 15 variables seleccionadas por importancia. Este mecanismo representa el escenario más favorable para la imputación, ya que no introduce ningún sesgo estructural y las técnicas multivariantes pueden recuperar la información con relativa fiabilidad.

2) **MAR (Missing At Random)**

Para la simulación MAR, se asumió que los valores faltantes dependen de otras variables observadas. Concretamente, se identificaron **cuatro variables condicionantes** consideradas relevantes y plausibles desde el punto de vista clínico y social:

- *Age*: se definió como grupo de interés a los mayores de 60 años.
- *Poverty*: se seleccionó el cuartil inferior del índice de pobreza.
- *HealthGen*: se enfocó en quienes declararon una percepción de salud *Poor*.
- *Education*: se eligieron los individuos con un nivel educativo equivalente a "8th Grade".

A partir de estas condiciones, se filtró un subconjunto de **4.018 individuos** (aproximadamente el 40,76 **%** del total), y únicamente sobre ese subconjunto se introdujeron faltantes en las 15 variables seleccionadas, excluyendo expresamente las cuatro condicionantes. De esta forma, se simula un patrón de no respuesta estructurado e imputable, coherente con el supuesto MAR.

3) **MNAR (Missing Not At Random)**

El mecanismo MNAR se diseñó bajo la hipótesis de que la ausencia depende directamente del valor de la propia variable. Para ello se diferenciaron dos grupos dentro de las 15 variables seleccionadas:

- En las **categóricas** (como *HHIncome*, *AgeDecade* y *HealthGen*), se eligieron categorías específicas que podrían asociarse con mayor probabilidad de omisión voluntaria (por ejemplo, edades elevadas, ingresos bajos o percepción de salud deficiente).
- En las **numéricas**, se definieron umbrales en los **extremos del rango** y, de forma parecida a las categóricas se introdujeron NA en los extremos que podrían asociarse con mayor probabilidad de omisión voluntaria. Por ejemplo NA en valores altos de *AlcoholYear* (por su connotación negativa) y en valores bajos de *SleepHrsNight*, asumiendo que algunos individuos podrían evitar reportarlos por motivos personales o sociales.

Este mecanismo representa el escenario más adverso para los imputadores, ya que los valores ausentes no pueden explicarse a partir de otras variables observadas, y la imputación requiere inferencias indirectas o supuestos fuertes.

3.5. *Métodos de imputación utilizados*

Este trabajo compara seis técnicas de imputación, seleccionadas por su variedad metodológica, nivel de complejidad y uso habitual en entornos reales. Todas ellas fueron implementadas en Python a través del script "*Experimento.ipyn*b" (ver Anexo), garantizando condiciones homogéneas de aplicación sobre los distintos datasets.

La siguiente tabla resume los métodos utilizados, su naturaleza y la forma concreta en que fueron integrados en el flujo de trabajo:

Método	Tipo de imputación	Implementación en Python	Aplicación práctica
Media	Univariado numérico	SimpleImputer(strategy='mean')	Sustituye NA por la media
Mediana	Univariado numérico	SimpleImputer(strategy='median')	Sustituye NA por la mediana
kNN	Multivariado	KNNImputer(n_neighbors=5)	Estima NA en función de vecinos
MICE	Multivariado	hyperimpute.MultivariateImputer(method='mice')	Imputación iterativa condicional
MissForest	Multivariado	hyperimpute.MultivariateImputer(method='missforest')	Bosques aleatorios iterativos
GAIN	Deep learning	hyperimpute.MultivariateImputer(method='gain')	Red generativa adversaria

Tabla 5: Métodos de imputación utilizados: tipo, implementación y aplicación

Cada técnica avanzada adopta una lógica distinta para imputar las variables en función de su naturaleza:

- **MICE** modela cada variable condicionalmente al resto: usa regresión lineal para las numéricas y regresión logística multiclase para las categóricas. La imputación se realiza de forma secuencial y iterativa, refinando progresivamente los valores estimados hasta converger.
- **MissForest** utiliza modelos de Random Forest adaptados al tipo de variable: RandomForestRegressor para variables numéricas y RandomForestClassifier para las categóricas. Cada iteración mejora la predicción de los valores ausentes usando como predictores el resto de las variables, incluso aquellas ya imputadas en pasos anteriores.

- **GAIN** introduce un enfoque completamente distinto basado en redes generativas adversarias. El modelo entrena un generador para crear imputaciones plausibles y un discriminador que intenta distinguir entre valores reales e imputados. Esta arquitectura permite capturar patrones complejos y relaciones no lineales entre variables.

En contraste, los métodos simples como media o mediana actúan de forma univariada y no tienen en cuenta ninguna relación entre variables. En estos casos, las variables categóricas se imputan siempre con la moda, entendida como la categoría más frecuente en el conjunto de entrenamiento.

Todas las técnicas se aplicaron exclusivamente sobre el conjunto de entrenamiento, replicando posteriormente las transformaciones sobre el test para garantizar que no se produce fuga de información (*data leakage*) entre fases.

3.6. Modelos de aprendizaje utilizados

Con el objetivo de evaluar el efecto de cada técnica de imputación sobre el rendimiento predictivo, se emplearon tres modelos de clasificación binaria representativos de distintos enfoques: lineal, basado en distancias y de ensamblado. Esta variedad permite detectar si el impacto de la imputación es consistente entre algoritmos con lógicas internas diferentes.

Los modelos utilizados fueron los siguientes:

1) **Regresión logística**: modelo lineal ampliamente utilizado por su interpretabilidad y eficiencia. Se configuró con *max_iter* = 1000 para asegurar convergencia, y *random_state* = 42 para garantizar reproducibilidad. Al no modificarse el parámetro *penalty*, se mantuvo la **regularización L2** por defecto, que penaliza los coeficientes de gran magnitud y ayuda a evitar el sobreajuste.
2) **k-Nearest Neighbors (k-NN)**: clasificador no paramétrico basado en la distancia euclidiana. Se utilizó con $k = 5$, tras estandarizar las variables numéricas, dado que el modelo es sensible a la escala de los predictores. Su simplicidad estructural lo convierte en un buen indicador de cómo la imputación afecta a modelos basados en vecindad.
3) **Random Forest**: conjunto de árboles de decisión entrenados de forma independiente y agregados por votación. Se utilizó con 100 árboles y sin restricción de profundidad (*max_depth* = "None"), permitiendo capturar relaciones no lineales y manejar variables mixtas sin transformaciones adicionales. Su capacidad de generalización lo hace especialmente útil en escenarios complejos y con interacción entre variables.

Cada modelo fue entrenado únicamente sobre datos ya imputados, respetando la división entre entrenamiento y test, y su rendimiento se evaluó mediante validación cruzada. Esta configuración permite valorar con mayor precisión el efecto real de la imputación sobre la capacidad predictiva del sistema.

3.7. *Métricas de evaluación*

Para valorar el rendimiento de los modelos entrenados tras la imputación, se utilizaron tres métricas complementarias que permiten analizar distintos aspectos de la clasificación binaria. La elección de estas métricas responde tanto a su relevancia general como a las características particulares del problema, especialmente el **desbalanceo de clases** existente en la variable objetivo (diabetes), que será tratado más detalladamente en la siguiente sección.

		Predicción	
		Positivos	**Negativos**
Observación	**Positivos**	Verdaderos Positivos (VP)	Falsos Negativos (FN)
	Negativos	Falsos Positivos (FP)	Verdaderos Negativos (VN)

Figura 2: Matriz de Confusión

Las métricas utilizadas fueron las siguientes:

1) **F1-score**

Combina precisión y exhaustividad (*recall*) en una única medida, calculando su media armónica. Es especialmente útil cuando la clase positiva es minoritaria, ya que penaliza tanto los falsos positivos como los falsos negativos. Se define como:

$$F1 - score = \frac{2 \cdot Precision \cdot Recall}{Precision + Recall} \quad \text{donde} \quad Precision = \frac{TP}{TP + FP}, \quad Recall = \frac{TP}{TP + FN}$$

Esta métrica resulta clave en este estudio, al reflejar con mayor fidelidad el rendimiento sobre la clase minoritaria.

2) **Área bajo la curva ROC (AUC-ROC)**

Mide la capacidad del modelo para distinguir entre clases, considerando todos los umbrales posibles de decisión. Representa gráficamente la relación entre la tasa de verdaderos positivos (*TPR*) y la tasa de falsos positivos (*FPR*). Aunque es una métrica estándar, puede resultar menos informativa en escenarios desbalanceados.

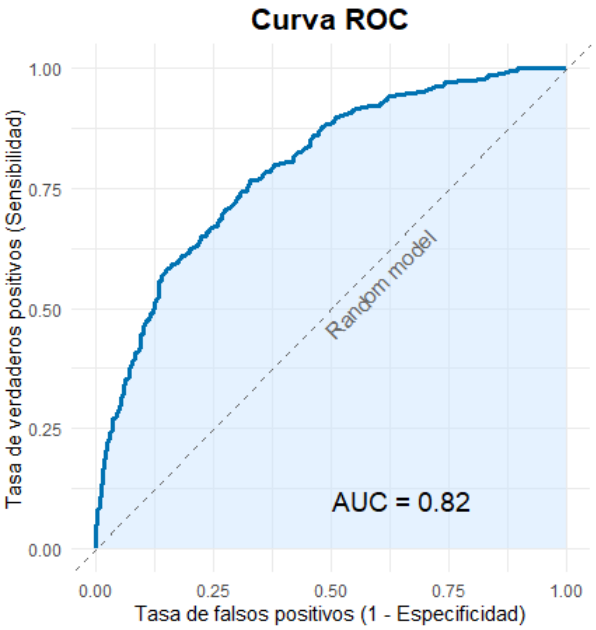

Figura 3: Ejemplo de una curva ROC

3) **Área bajo la curva Precision-Recall (PR AUC)**

Evalúa la relación entre precisión y recall a lo largo de distintos umbrales, centrándose exclusivamente en la clase positiva. A diferencia de la *ROC*, esta métrica se ve directamente afectada por el desequilibrio entre clases, y por tanto resulta más representativa en contextos como el del presente trabajo.

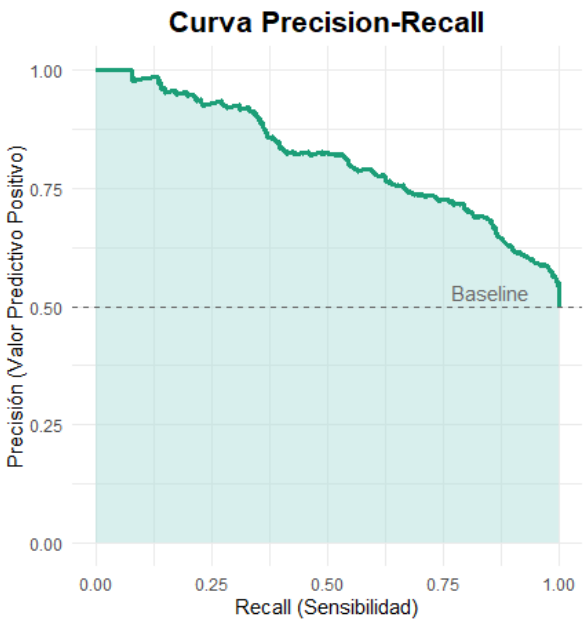

Figura 4: Ejemplo de una curva PR

3.8. Diseño experimental

El diseño experimental de este trabajo se ha estructurado para garantizar una evaluación rigurosa y sistemática del impacto que tienen los distintos métodos de imputación sobre el rendimiento de modelos de clasificación. A continuación, se detallan los pasos clave aplicados de forma uniforme a cada uno de los diez datasets utilizados en el estudio.

3.8.1. <u>División train/test</u>

Cada dataset (ya imputado o con valores simulados faltantes) se divide en dos subconjuntos mediante una partición estratificada: **80 % para entrenamiento y 20 % para test**, manteniendo la proporción original entre clases. Esta división se realiza utilizando *train_test_split* con una semilla fija (*random_state*=42) para garantizar la reproducibilidad del experimento. La separación se mantiene constante en todas las combinaciones de imputación y modelo.

3.8.2. <u>Validación cruzada</u>

Dentro del conjunto de entrenamiento se aplica una **validación cruzada estratificada de 5 pliegues**, implementada mediante *StratifiedKFold* con barajado previo y semilla establecida. Este procedimiento permite evaluar de forma más robusta el rendimiento del modelo en cada *fold*, evitando sesgos debidos a particiones concretas y respetando el desbalance de clases durante el entrenamiento. La métrica evaluada en la validación es la AUC (aunque en el análisis posterior se incluyen también *F1*-score y PR AUC).

3.8.3. <u>Aplicación de SMOTE</u>

Dado el marcado desbalance en la variable objetivo *diabetes* (con **proporción positiva 7,7%**), se incorporó la técnica **SMOTE** (Synthetic Minority Over-sampling Technique) sobre

el conjunto de entrenamiento, una vez completado el proceso de imputación. SMOTE genera nuevas instancias sintéticas de la clase minoritaria, interpolando entre observaciones reales cercanas. Este paso se aplica exclusivamente sobre los datos de entrenamiento y antes de la validación cruzada, para evitar fugas de información entre fases. La implementación se realiza con SMOTE(random_state=42) desde la librería *imbalanced-learn*, y forma parte del pipeline cuando se activa el parámetro *balance_method*='smote'.

3.8.4. Estabilidad del modelo

Aunque no se realizan repeticiones múltiples con distintas semillas, se aplican semillas fijas en todos los puntos críticos del pipeline (división de datos, SMOTE, validación cruzada, inicialización de modelos). Esto garantiza la **reproducibilidad total** del experimento y permite comparar directamente los resultados entre métodos de imputación y modelos sin interferencias debidas a variabilidad aleatoria.

4. Resultados

4.1. Comparativa global de métodos de imputación

El primer análisis realizado busca comparar el rendimiento general medio de cada técnica de imputación, independientemente del tipo de mecanismo de ausencia, del porcentaje de valores faltantes y del modelo de aprendizaje utilizado. El objetivo es obtener una primera visión agregada del comportamiento de cada método en términos de capacidad predictiva.

La **Tabla 6** recoge el rendimiento medio de cada método de imputación según tres métricas evaluadas sobre el conjunto de test: F1-score, AUC ROC y PR AUC. El orden de la tabla responde al valor medio del F1-score, que es la métrica prioritaria en este estudio dada la naturaleza desbalanceada del conjunto de datos.

Método de imputación	F1	AUC-ROC	PR AUC
GAIN	0.402	0.878	0.463
MissForest	0.402	0.870	0.449
Mediana	0.391	0.862	0.429
Media	0.390	0.861	0.429
kNN	0.380	0.859	0.426
MICE	0.376	0.872	0.443

Tabla 6: Rendimiento medio de los métodos de imputación en test (ordenado por F1-score)

Como se observa, los métodos GAIN y MissForest destacan de forma consistente por encima del resto en todas las métricas, lo que refleja su capacidad para preservar estructuras no lineales y relaciones multivariantes. Las estrategias más simples (como imputar con la media o la mediana) ofrecen un rendimiento sorprendentemente competitivo en este contexto, especialmente cuando se combinan con modelos robustos como Random Forest. Por el contrario, el método kNN muestra un comportamiento más modesto, posiblemente por su sensibilidad a la escala, la distribución local y la alta dimensionalidad del espacio imputado.

Para complementar este análisis, la **Figura 5** muestra un gráfico de barras con las 20 mejores combinaciones individuales de método de imputación y modelo, según el F1-score alcanzado. En esta visualización se aprecia que la gran mayoría de estas combinaciones incorporan el modelo Random Forest, lo que confirma su robustez frente a distintas técnicas de imputación. Además, se evidencia cómo GAIN ocupa las primeras posiciones, seguido muy de cerca por métodos simples como la media y la mediana, lo que resulta llamativo desde una perspectiva práctica.

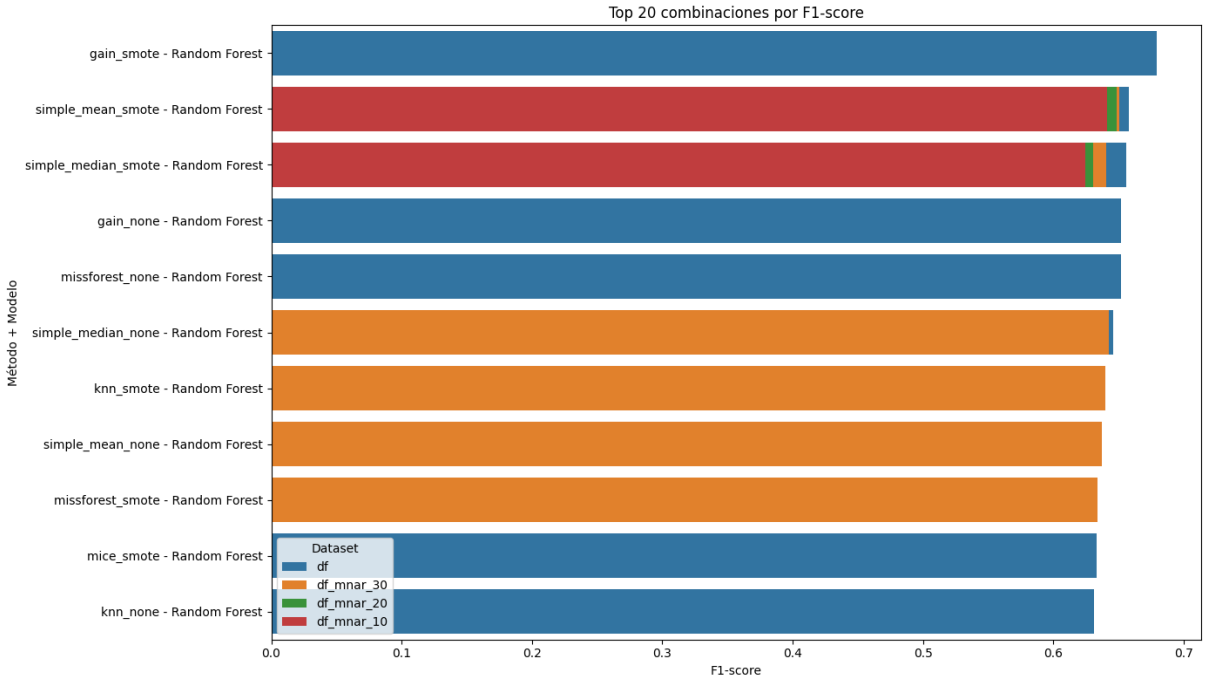

Figura 5: Top 20 combinaciones de imputación y modelo según F1-score

4.2. Resultados según mecanismo y porcentaje de valores faltantes

Una de las variables que más condiciona el rendimiento de los métodos de imputación es el mecanismo de ausencia que origina los datos faltantes. En este estudio se han simulado tres tipos distintos (MCAR, MAR y MNAR), cada uno aplicado a un conjunto de variables concretas con distintos grados de complejidad estructural. A su vez, cada mecanismo se ha combinado con tres niveles de ausencia: 10 %, 20 % y 30 %, lo que permite explorar el impacto conjunto de estos factores en el rendimiento predictivo. La **Figura 6** recoge el F1-score medio obtenido por cada técnica de imputación en cada uno de los tres mecanismos. Esta comparación permite observar qué métodos muestran mayor robustez ante patrones de ausencia estructurados (como en MAR o MNAR) y cuáles se ven más afectados por la aleatoriedad total que caracteriza al escenario MCAR.

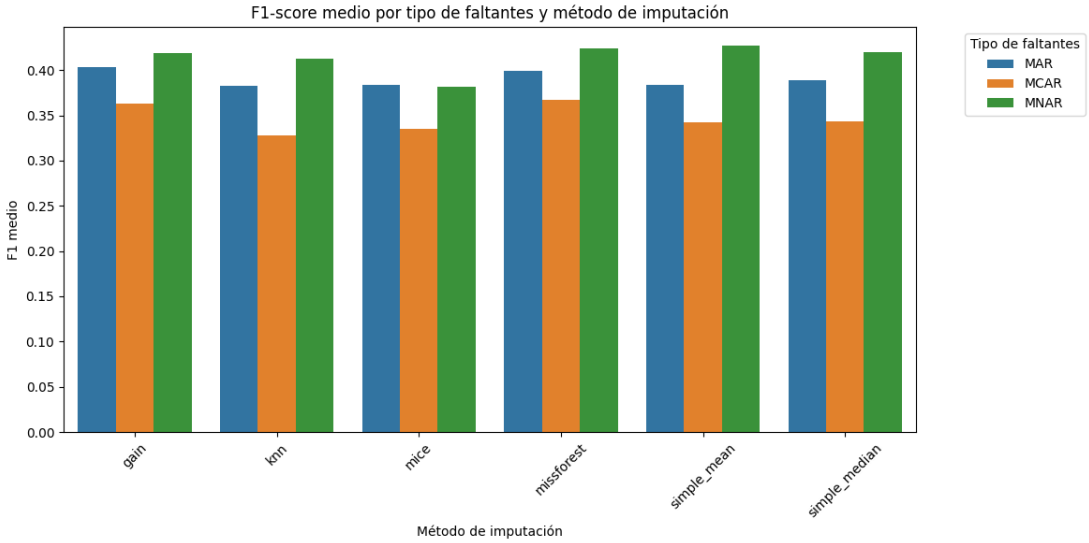

Figura 6: F1-score medio por tipo de faltantes y método de imputación

De forma general:

- Bajo **MCAR**, todos los métodos tienden a rendir peor, dado que no existe estructura aprovechable para predecir los valores perdidos.
- En **MAR**, se obtiene un rendimiento medio más alto y estable, ya que el patrón de ausencia depende de otras variables observables.
- En **MNAR**, destacan especialmente algunos métodos como *MissForest* o *SimpleMedian*, que logran aprovechar ciertos patrones internos generados al omitir información en valores extremos o categorías concretas. Esto sugiere que, pese a la teórica dificultad del escenario MNAR, su **estructura predecible** permite a ciertos algoritmos modelar eficazmente la ausencia.

Para analizar el efecto del porcentaje de valores ausentes, se ha representado en la **Figura 7** la evolución del F1-score medio en cada mecanismo a medida que crece el nivel de NA.

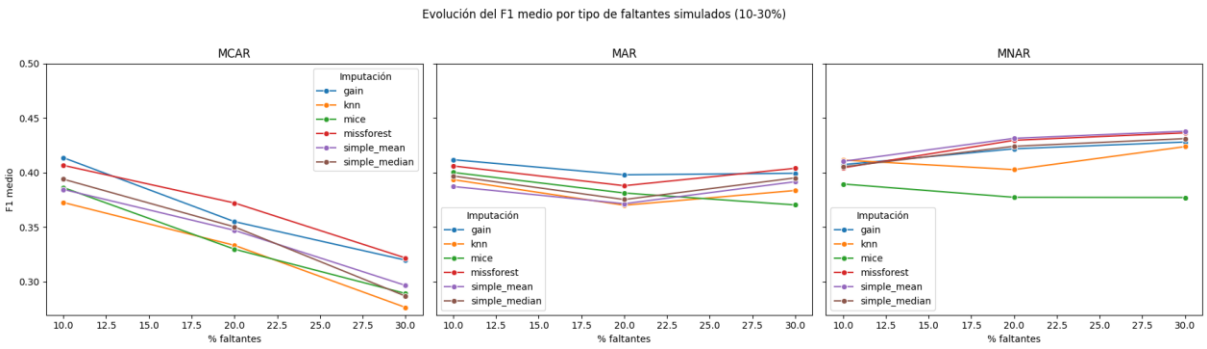

Figura 7: Evolución del F1-score medio según mecanismo y porcentaje de valores ausentes

Esta figura permite observar que:

- En **MCAR**, el rendimiento cae progresivamente con mayor porcentaje de NA.
- En **MAR**, los métodos mantienen una estabilidad notable incluso al 30 % de ausencia.
- En **MNAR**, la tendencia es en la mayoría de los casos incluso ascendente, lo que refuerza la idea de que la forma de simulación ha dotado a este mecanismo de una cierta regularidad explotable por algunos algoritmos.

Como complemento visual, la **Figura 8** presenta un *heatmap* que combina también simultáneamente ambas dimensiones: mecanismo y porcentaje, mostrando el F1-score promedio en cada celda. Este resumen permite comparar de forma clara cuáles son las combinaciones más favorables y cuáles penalizan más la imputación. Como se puede observar los 3 valores mas altos son para el mecanismo MNAR, y estos aumentan a medida que aumenta el porcentaje de faltantes; todos ellos pierden de todas formas al ser comparados con el F1 medio del dataset original con 0% de faltantes. El peor resultado lo tiene, como era predecible tras los resultados anteriores, el mecanismo MCAR con el máximo porcentaje de faltantes imputados (30%).

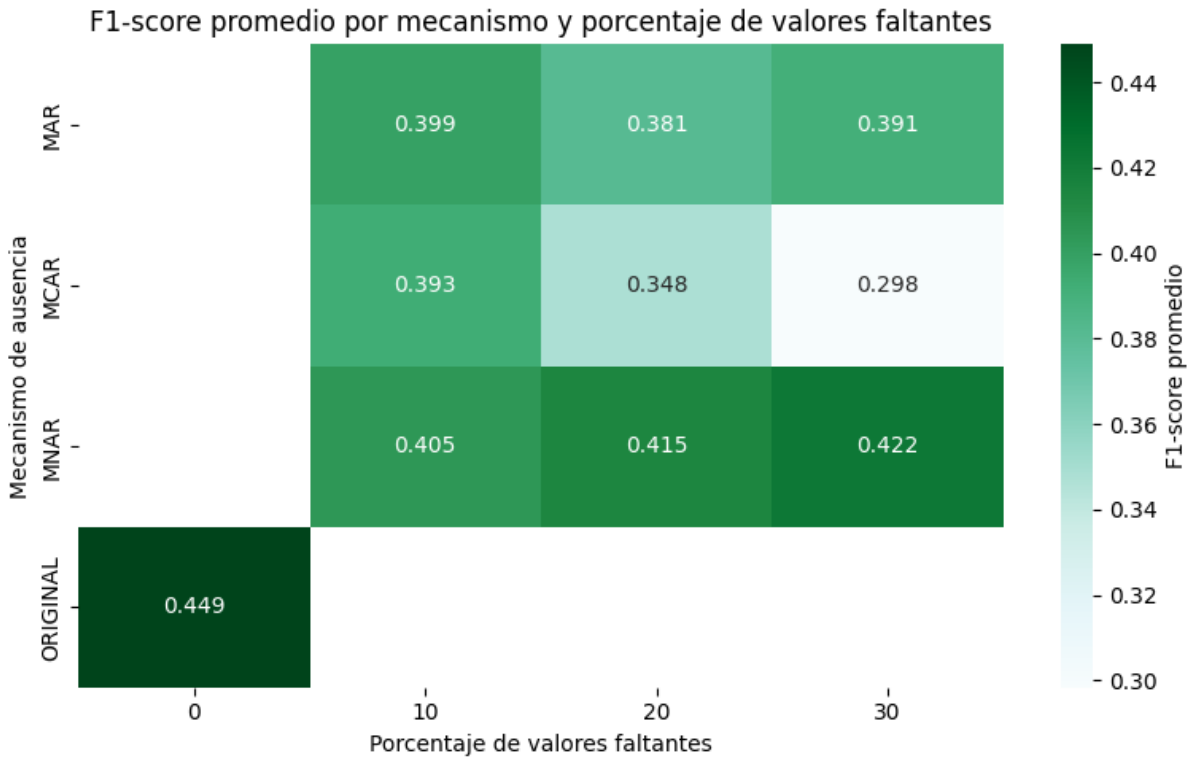

Figura 8: Heatmap del F1-score medio por combinación de mecanismo y porcentaje de valores ausentes

4.3. Variabilidad y estabilidad de las imputaciones

Una de las dimensiones más relevantes en la evaluación de los métodos de imputación es su capacidad para ofrecer resultados estables ante distintas configuraciones experimentales. En este trabajo se ha medido esta estabilidad a través de dos perspectivas complementarias: por un lado, el análisis de **la variabilidad interna** mediante la desviación estándar de las métricas de evaluación; y por otro, la **robustez global**, entendida como la capacidad de alcanzar buenos resultados en múltiples contextos.

La **Figura 9**, incluida a continuación, muestra la desviación estándar de F1-score, AUC-ROC y PR AUC para cada técnica de imputación, agregando todos los modelos, datasets y niveles de porcentaje de ausencia. Como puede observarse, no existe una correspondencia directa entre complejidad del método y estabilidad: por ejemplo, GAIN, que utiliza redes generativas, no es el método más variable, ni la media o la mediana se sitúan sistemáticamente entre los más estables. MICE presenta, de hecho, las desviaciones más bajas en AUC y F1, mientras que MissForest mantiene una dispersión media en todas las métricas.

Más allá de la dispersión global, resulta útil analizar la estructura interna de la distribución de resultados obtenidos por cada imputador. La **Figura 10**, que representa los boxplots de F1-score por método, permite observar visualmente la amplitud de los valores obtenidos, su simetría y la presencia de posibles valores extremos.

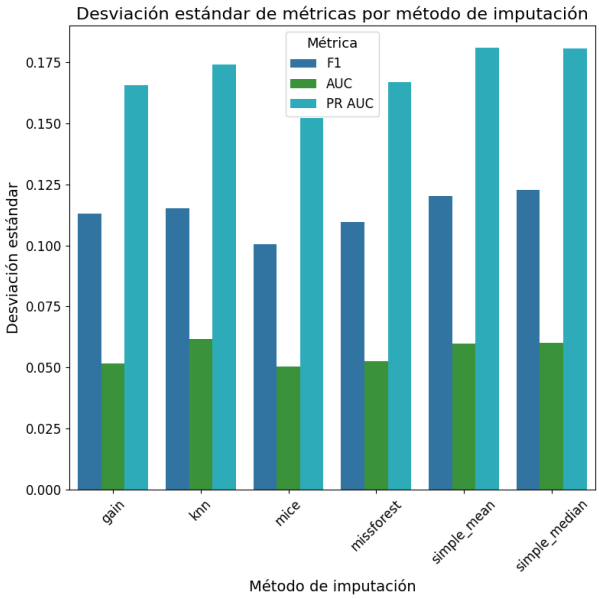

Figura 9: Desviación estándar de métricas por método de imputación

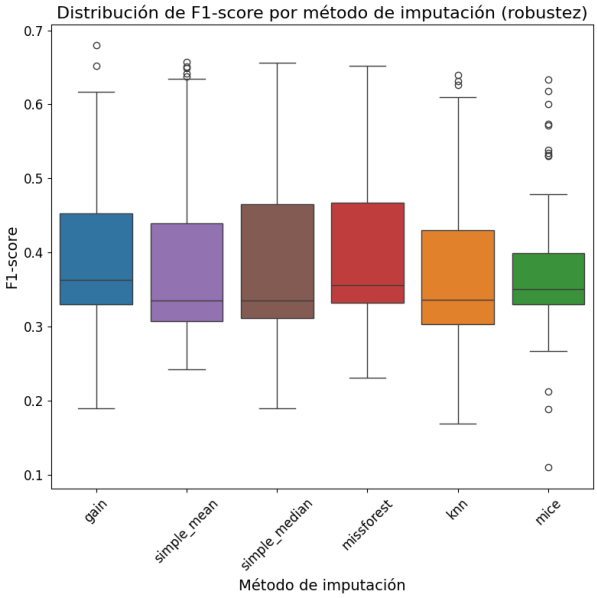

Figura 10: Distribución de F1-score por método de imputación (boxplot)

Como puede apreciarse, los métodos GAIN, MissForest y simple_median muestran distribuciones con un rango amplio y valores máximos elevados, lo que indica que tienen el potencial de alcanzar altos niveles de rendimiento en ciertos contextos. A su vez, *MICE* destaca por tener con diferencia el menor rango intercuartílico.

Los resultados numéricos se recogen en la **Tabla 7**, que incluye los estadísticos principales de F1-score por método de imputación: media, desviación estándar, mínimo, máximo y rango. Esta tabla sintetiza los patrones observados gráficamente y permite una comparación directa entre métodos.

Imputación	F1 Mean	F1 Std	F1 Min	F1 Max	F1 Range
Media	0.3898	0.1202	0.2428	0.6577	0.4149
MissForest	0.4021	0.1095	0.2312	0.6522	0.4210
Mediana	0.3905	0.1227	0.1893	0.6557	0.4664
kNN	0.3801	0.1153	0.1687	0.6400	0.4713
GAIN	0.4021	0.1131	0.1893	0.6795	0.4902
MICE	0.3757	0.1005	0.1098	0.6336	0.5238

Tabla 7: Estadísticos de F1-score por método de imputación

Por ejemplo, MICE presenta el mayor rango absoluto de todos los métodos (0.5238), lo cual contrasta con su pequeña caja en el boxplot (**Figura 10**). Esta paradoja sugiere que MICE es muy estable en la mayoría de los contextos, pero puede generar resultados extremos en situaciones específicas. GAIN, kNN y simple_median también presentan rangos elevados, tanto totales como intercuartílicos, lo que indica una mayor sensibilidad a las condiciones experimentales.

Por el contrario, MissForest muestra una de las distribuciones más compactas, tanto en términos de rango total como de dispersión intercuartílica, lo que lo posiciona como uno de los métodos más estables dentro del conjunto evaluado. En esta misma línea, simple_median tiene un F1 medio apenas inferior al de los imputadores avanzados, y destaca por mantener una distribución más homogénea. Esto sugiere que, a pesar de su simplicidad, puede ofrecer una **fiabilidad estructural** competitiva en escenarios prácticos.

4.4. Comparación de los modelos predictivos por método de imputación

Una vez analizadas las diferencias globales entre técnicas de imputación, resulta de especial interés examinar cómo se comportan los **modelos de clasificación** individualmente según el imputador empleado. Esta comparación permite evaluar si existe alguna interacción relevante entre el tipo de imputación y el modelo aplicado sobre los datos ya completados.

La **Figura 11**, incluida a continuación, resume gráficamente los valores promedio obtenidos por cada modelo —**kNN**, **regresión logística** y **Random Forest**— para las métricas F1-score, ROC-AUC y PR AUC, según el método de imputación utilizado.

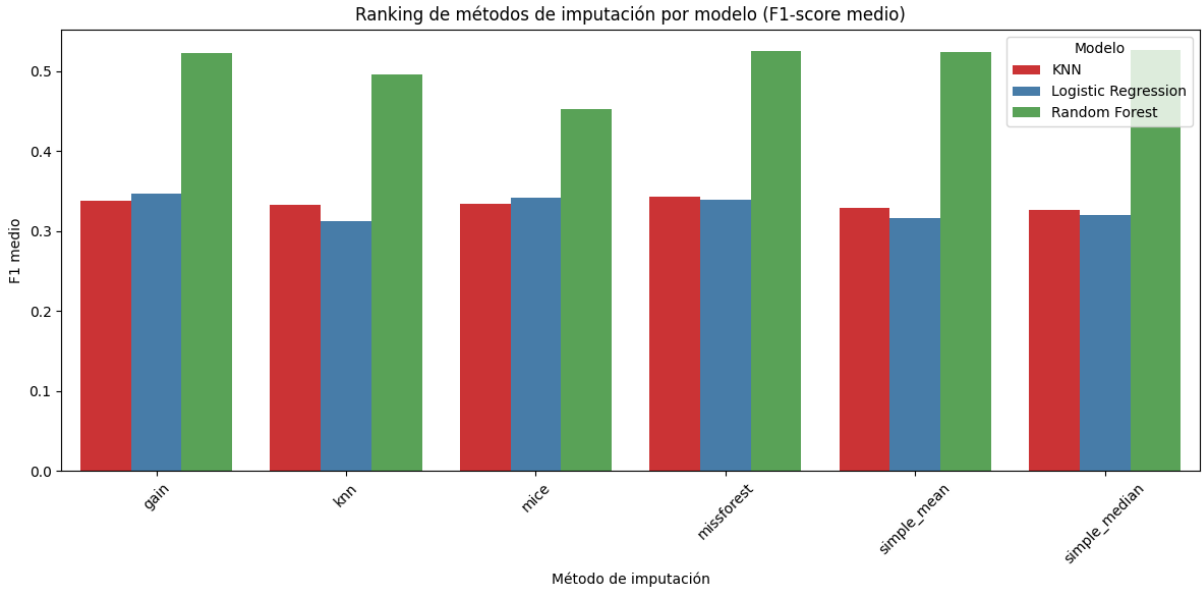

Figura 11: Comparación de métricas medias por modelo y método de imputación

Como puede observarse, el modelo **Random Forest** presenta los mejores resultados en todas las métricas, con diferencia respecto a los otros dos. Su *F1-score* medio oscila entre 0.45 y 0.53, dependiendo del imputador, y sus valores de AUC y PR AUC también se sitúan

claramente por encima del resto. Esta superioridad se mantiene estable independientemente del tipo de imputación aplicada.

La **regresión logística** ocupa una posición intermedia, con F1 entre 0.31 y 0.35, y AUC alrededor de 0.86–0.88. Aunque su rendimiento es inferior al de Random Forest, muestra una buena regularidad entre imputadores. Su mejor combinación se obtiene con GAIN, tanto en F1 como en PR AUC.

En cambio, el modelo **k-NN** presenta un rendimiento global inferior, pero con una dispersión muy limitada entre imputadores. Tal como se recoge en la **Tabla 8**, la variación de F1 entre su mejor imputación (MissForest, 0.3424) y la peor (MICE, 0.3267) es de tan solo 0.0158 puntos. En cambio, la regresión logística muestra una variación más notable (≈0.0342), y Random Forest es el modelo cuya F1 media fluctúa más en función del imputador (rango ≈0.0737). Este comportamiento sugiere que, mientras algunos modelos mantienen un rendimiento homogéneo, otros se ven más afectados por el tipo de imputación, lo cual será discutido con más detalle en el capítulo siguiente.

Modelo	F1 Mínimo	F1 Máximo	Rango F1
k-NN	0.3267	0.3424	0.0158
Logistic Regression	0.3125	0.3468	0.0342
Random Forest	0.4518	0.5256	0.0737

Tabla 8: Rango de F1-score entre imputadores por modelo

4.5. Impacto del balanceo de clases (SMOTE)

Dado que la variable objetivo presenta un desequilibrio marcado (la clase positiva representa tan solo un 7,7 % del total), se evaluó el efecto de aplicar la técnica de sobremuestreo **SMOTE** (Synthetic Minority Over-sampling Technique) sobre el rendimiento predictivo. Para ello, se compararon las métricas medias de F1-score, ROC AUC y PR AUC obtenidas con y sin SMOTE, agregando todos los experimentos realizados.

La **Tabla 9**, incluida a continuación, resume estos resultados. Se observa una mejora significativa en F1-score (+0.0581) al aplicar SMOTE, lo cual indica que los modelos son más capaces de identificar correctamente ejemplos de la clase minoritaria sin perder demasiada precisión. En contraste, el valor medio de ROC AUC mejora ligeramente (+0.0078), mientras que el PR AUC sufre una leve caída (−0.0261).

Balanceo	F1	ROC AUC	PR AUC
None	0.3610	0.8632	0.4528
SMOTE	0.4191	0.8710	0.4268
Diferencia (SMOTE - None)	+0.0581	+0.0078	−0.0261

Tabla 9: Efecto medio de SMOTE sobre las métricas de evaluación

Este patrón de resultados pone de relieve un fenómeno conocido en contextos con clases desbalanceadas: SMOTE mejora el F1-score general a costa de reducir ligeramente la precisión en los primeros umbrales de decisión, lo cual afecta negativamente al área bajo la curva de *precisión-recall*. Este efecto será analizado con mayor detalle en el capítulo de discusión.

4.6. Síntesis visual de los resultados experimentales

Además de los análisis numéricos ya expuestos, esta sección presenta una serie de representaciones visuales que permiten observar los patrones de comportamiento de los distintos métodos de imputación y modelos de clasificación. Estas visualizaciones se han generado a partir del conjunto completo de resultados y tienen como objetivo ofrecer una perspectiva más intuitiva sobre el rendimiento relativo de cada combinación, así como sobre la relación entre las distintas métricas evaluadas. La sección se organiza en tres bloques: *heatmaps* de rendimiento, radar plots comparativos y análisis de correlación entre métricas.

1) Heatmaps de rendimiento por modelo e imputador

La **Figura 12**, incluida a continuación, muestra un mapa de calor con el valor medio de F1-score para cada combinación de imputador y modelo de clasificación. Esta visualización permite identificar de forma rápida cuáles son las combinaciones que han alcanzado mayores niveles de rendimiento en esta métrica.

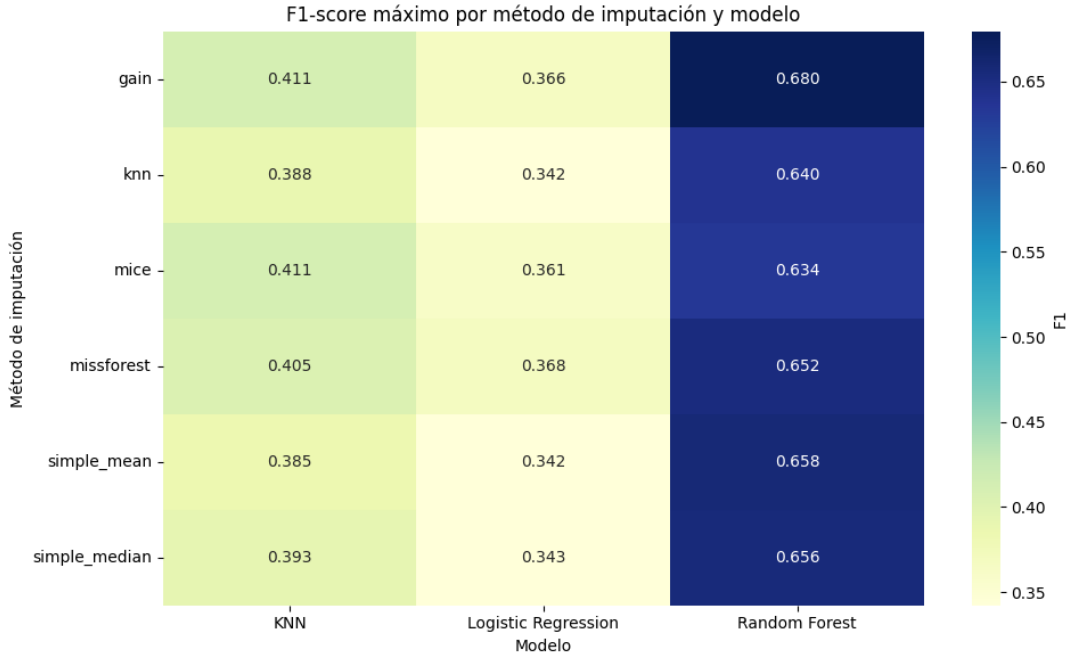

Figura 12: Heatmap de F1-score medio por combinación de modelo e imputador

Se observan valores de F1 notablemente más altos en las combinaciones que incluyen Random Forest junto con imputadores como GAIN o MissForest. Las configuraciones que incluyen imputadores simples, como *media* o *mediana*, también alcanzan valores aceptables con este modelo. En contraste, el modelo k-NN tiende a presentar valores más bajos de F1 en todas sus combinaciones.

La próxima figura (**Figura 13)** por su parte muestra el heatmap correspondiente a la métrica AUC-ROC. En este caso, los valores son generalmente muy altos para todas las combinaciones, aunque se perciben ligeras diferencias entre imputadores. Algunas combinaciones con Random Forest o regresión logística alcanzan valores superiores a 0.89.

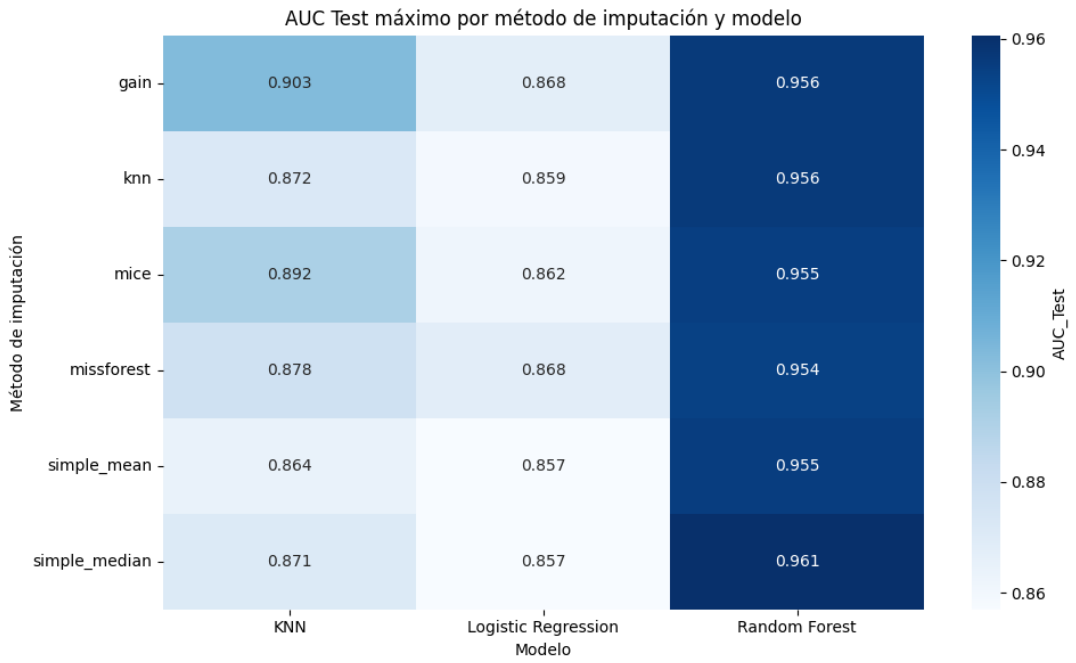

Figura 13: Heatmap de AUC-ROC medio por combinación de modelo e imputador

En la **Figura 14**, se representa el heatmap de PR AUC. En esta métrica, las diferencias entre modelos y métodos de imputación son algo más marcadas. Las combinaciones con imputadores avanzados suelen presentar valores más altos con modelos kNN y los valores de Random Forest vuelven a ser notoriamente más altos.

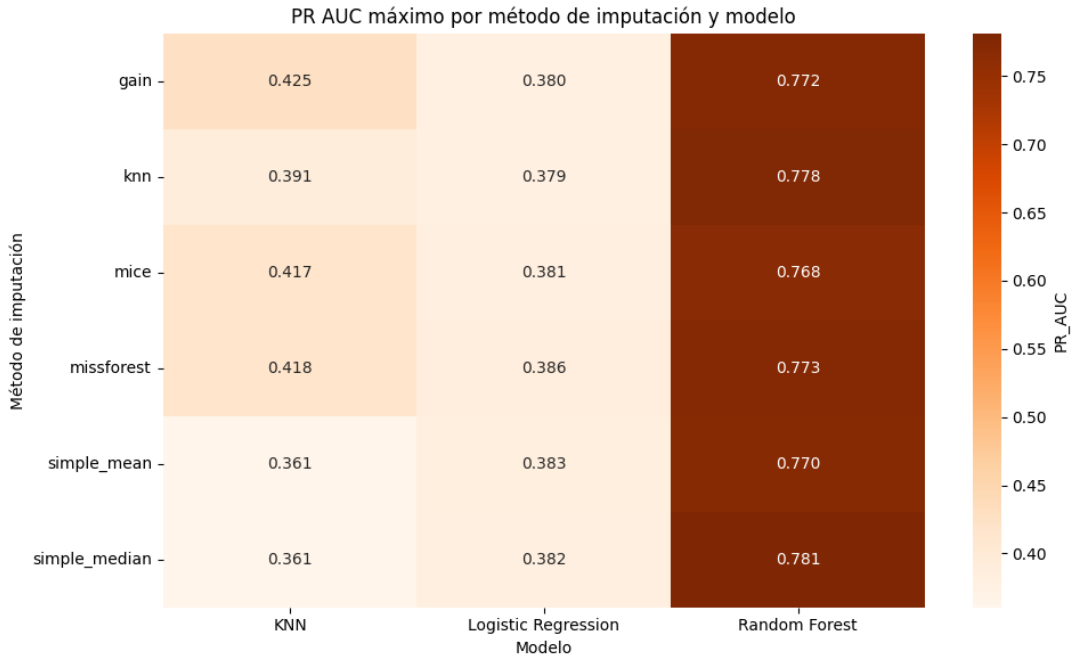

Figura 14: Heatmap de PR AUC medio por combinación de modelo e imputador

2) Radar plots comparativos

A continuación, se presenta un radar plot en la **Figura 15** que permite comparar, para cada imputador, los valores medios obtenidos en F1-score, AUC-ROC y PR AUC. Este tipo de visualización facilita la observación del perfil general de rendimiento de cada técnica de imputación.

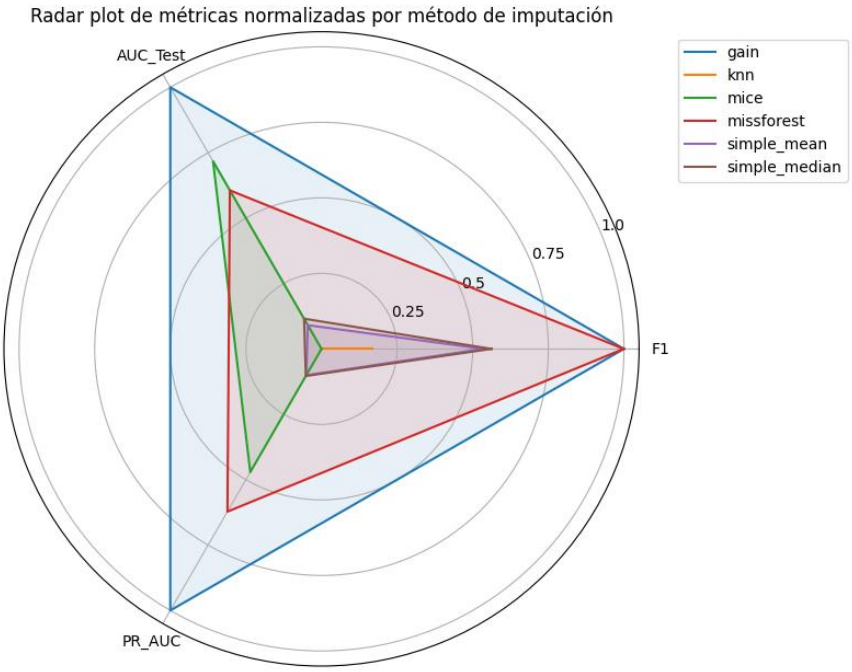

Figura 15: Radar plot de métricas promedio por método de imputación

Se observa que algunos imputadores tienden a ocupar áreas más amplias en el gráfico, reflejando valores medios elevados en las tres métricas. Otros, en cambio, muestran perfiles más contenidos, con valores concentrados en una zona intermedia del gráfico.

La **Figura 16** desagrega esta visualización, mostrando un radar plot por combinación de imputador y modelo. Esta presentación permite ver, para cada combinación concreta, qué métricas se vieron más beneficiadas.

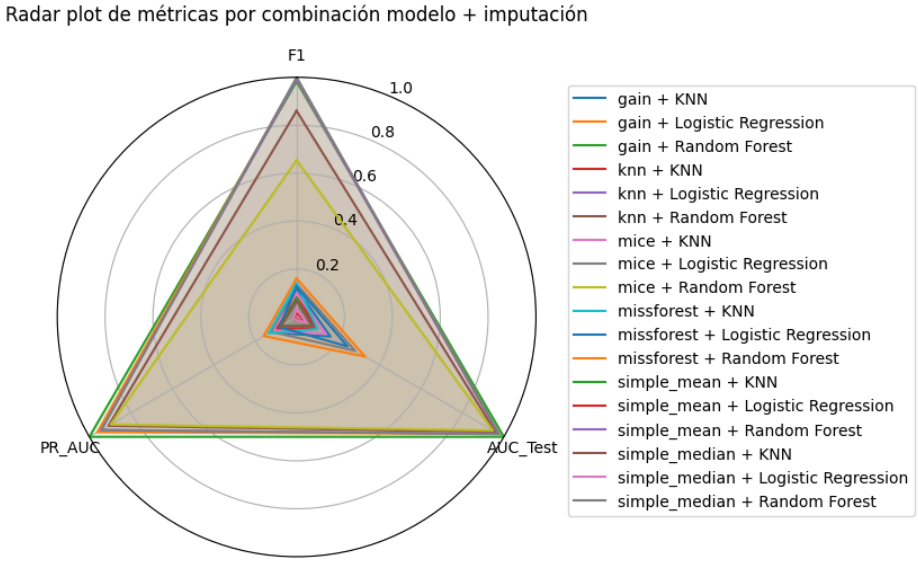

Figura 16: Radar plot de métricas por combinación de modelo e imputador

Las combinaciones que incluyen Random Forest tienden a ocupar posiciones periféricas en el gráfico, asociadas a valores medios altos. Otras combinaciones presentan un perfil más simétrico o contenido según la métrica predominante.

3) Correlación entre métricas

Por último, se ha calculado la correlación entre las tres métricas empleadas (**F1, AUC-ROC y PR AUC**) a lo largo de todas las combinaciones experimentales. Se muestra a continuación la **Figura 17**, generada a partir del conjunto completo de resultados, representa visualmente estas relaciones mediante una matriz de correlación.

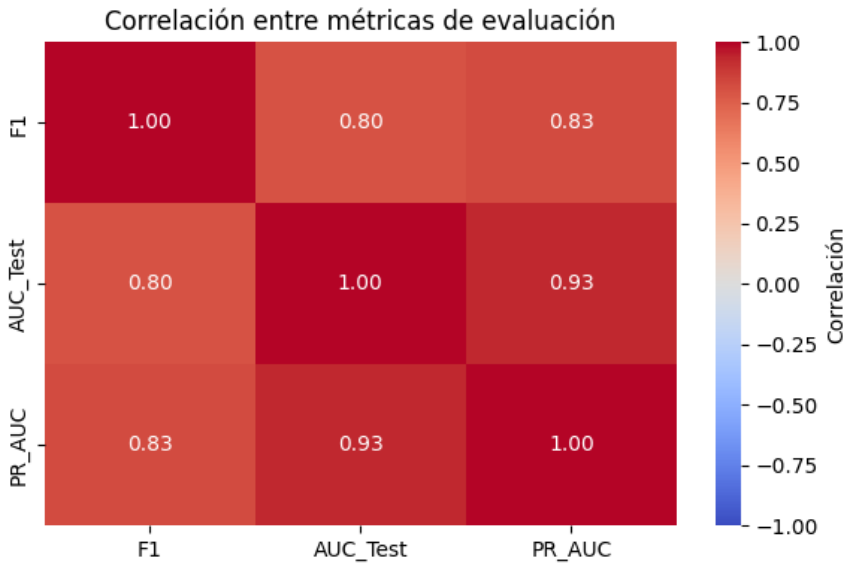

Figura 17: Correlación entre métricas de evaluación (F1, AUC-ROC, PR AUC)

Se aprecia una correlación positiva clara entre F1-score y PR AUC, lo cual es esperable dada la sensibilidad de ambas métricas al rendimiento sobre la clase positiva. En cambio, la correlación entre AUC-ROC y PR AUC es más débil, lo que puede explicarse por el hecho de que la AUC-ROC evalúa el comportamiento global del clasificador, mientras que la PR AUC se centra en la capacidad del modelo para manejar correctamente la clase minoritaria. Esta diferencia justifica el uso conjunto de ambas métricas en **entornos desbalanceados**.

Estas visualizaciones complementan los resultados obtenidos y ayudan a identificar patrones generales y combinaciones especialmente efectivas. Su análisis detallado servirá de base para la discusión crítica que se desarrolla en la siguiente sección.

5. Discusión

La evaluación sistemática realizada en el capítulo anterior ha puesto de manifiesto patrones de rendimiento claros, pero también matices importantes que merecen un análisis más profundo. Lejos de limitarse a comparar métricas en términos absolutos, este capítulo busca interpretar los resultados observados, identificar factores explicativos y valorar su coherencia con las expectativas teóricas y con los principios que subyacen a cada método. Asimismo, se abordarán las limitaciones del diseño experimental, las implicaciones para la práctica clínica y la comparación con estudios anteriores.

5.1. Análisis crítico de los resultados

5.1.1. Rendimiento de los métodos de imputación.

Cabe destacar la clara ventaja de los métodos de imputación basados en aprendizaje automático, en particular **GAIN** y **MissForest**, que han ofrecido sistemáticamente los mejores resultados en F1-score y AUC-ROC. Esta superioridad puede explicarse por su capacidad para capturar relaciones multivariantes complejas en los datos, algo especialmente valioso en un entorno como NHANES, donde las dependencias entre variables no son ni lineales ni triviales. **MissForest**, al basarse en bosques aleatorios, aprovecha estas relaciones de forma robusta, mientras que **GAIN** lo hace a través de una arquitectura adversarial que aprende patrones plausibles de imputación. La consistencia de su rendimiento sugiere que, incluso en escenarios simulados con distintos mecanismos de ausencia, son capaces de reconstruir la estructura interna de los datos con mayor fidelidad que los métodos más simples.

No obstante, esta ventaja no implica que los métodos simples (**media** y **mediana**) deban descartarse automáticamente. De hecho, los resultados muestran que su rendimiento es solo ligeramente inferior en algunas métricas, y que, en ciertos modelos como la regresión logística, llegan a ofrecer resultados competitivos. Esto puede explicarse por el hecho de que su simplicidad introduce menos ruido estructural y preserva la escala original de las variables, lo que puede ser útil en modelos lineales o cuando las imputaciones afectan a pocas columnas. Además, su bajo coste computacional y su estabilidad los convierten en una opción razonable en entornos con recursos limitados o cuando se requiere una solución rápida y reproducible.

5.1.2. Influencia del modelo de clasificación.

El modelo predictivo utilizado también ha mostrado ser un factor determinante. **Random Forest** ha liderado claramente el rendimiento en todas las métricas y para casi todos los imputadores. Esta observación refuerza la idea de que los clasificadores más complejos y no lineales son capaces de adaptarse mejor a las transformaciones que introduce la imputación, especialmente cuando esta no preserva las relaciones lineales originales. En cambio, el modelo **k-NN** ha mostrado un rendimiento global inferior, lo cual es coherente con su sensibilidad a la escala de las variables y a las distorsiones introducidas por la imputación.

Curiosamente, su comportamiento ha sido también el más homogéneo: el rango de F1-score entre imputadores ha sido el más bajo, lo que indica que es un modelo poco sensible a las diferencias entre métodos de completado, aunque también menos capaz de explotar sus ventajas.

5.1.3. Comportamiento diferencial de las métricas.

Los resultados han confirmado la utilidad de emplear más de una métrica de evaluación en contextos con clases desbalanceadas. El uso conjunto de **F1-score**, **AUC-ROC** y **PR AUC** ha permitido matizar los resultados y evitar interpretaciones sesgadas. Por ejemplo, algunos métodos que obtenían buenos resultados en **AUC-ROC** no destacaban en **PR AUC**, lo que refleja que estas métricas capturan aspectos distintos del rendimiento. La matriz de correlación entre métricas reveló una fuerte asociación entre **F1 *y* PR AUC**, mientras que la relación con **AUC-ROC** era más débil. Esto refuerza la idea de que, en problemas donde la clase positiva es minoritaria, las métricas centradas en precisión y exhaustividad ofrecen una imagen más fiel del rendimiento real.

5.1.4. Impacto del balanceo mediante SMOTE.

Un punto especialmente interesante ha sido el análisis del efecto del balanceo de clases mediante **SMOTE**. En general, **SMOTE** ha mejorado notablemente el F1-score, con un incremento medio cercano a seis puntos porcentuales. Esta mejora se debe a que el algoritmo introduce más ejemplos de la clase positiva, facilitando su detección por parte del modelo. Sin embargo, el PR AUC ha empeorado ligeramente con **SMOTE**, lo cual puede parecer contradictorio a primera vista. Una posible explicación es que el incremento de recall ha venido acompañado de una caída en la precisión, especialmente en los umbrales bajos, lo que penaliza la curva **precision-recall**. Además, es posible que la creación de ejemplos sintéticos haya introducido ruido en regiones del espacio de variables donde no había datos reales, afectando negativamente a la calibración del modelo.

5.1.5. Divergencias bajo distintos mecanismos de ausencia.

También se han observado divergencias significativas entre métodos, especialmente bajo mecanismos de ausencia más complejos como **MNAR**. Algunos imputadores han mostrado comportamientos menos robustos en estos escenarios, lo que sugiere que no todos los métodos son igualmente válidos para todas las formas de ausencia. GAIN, por ejemplo, ha mantenido un buen rendimiento en **MAR** y **MCAR**, pero ha sido algo más irregular en **MNAR**. MICE, en cambio, ha mostrado una alta variabilidad y cierta fragilidad cuando la ausencia afectaba a valores extremos o categorías socialmente sensibles, lo que plantea dudas sobre su fiabilidad en contextos reales donde los datos **MNAR** son frecuentes. Estas diferencias no deben entenderse como fallos de los métodos, sino como una consecuencia lógica de sus supuestos internos y de los tipos de dependencia que son capaces de modelar.

5.2. *Limitaciones del diseño experimental*

A pesar del rigor metodológico aplicado a lo largo del estudio, existen varias limitaciones inherentes al diseño experimental que conviene señalar. Estas no invalidan los resultados obtenidos, pero sí acotan su alcance y deben tenerse en cuenta al interpretar las conclusiones o al extrapolar los hallazgos a contextos reales.

- Una primera limitación reside en la **naturaleza artificial de los mecanismos de ausencia** empleados. Aunque se han simulado los tres tipos clásicos (MCAR, MAR y MNAR), y se ha hecho con cuidado conceptual y técnico, la generación de valores faltantes sigue estando sujeta a **supuestos simplificadores**. Por ejemplo, en el caso MAR se condiciona la ausencia a ciertas variables clave (edad, pobreza, educación, estado de salud), y en MNAR se omiten valores extremos o categorías socialmente sensibles, pero estas implementaciones son necesariamente una aproximación. En la realidad, los mecanismos de ausencia pueden ser mucho más difusos, dependientes de procesos desconocidos o incluso no observables.
- Otro aspecto relevante es que, al simular faltantes sobre una base de datos completa, se **parte de la premisa de que los valores observados son veraces**, cuando en la práctica esto no siempre es así. En datasets biomédicos como NHANES, algunos valores —aunque no estén registrados como ausentes— pueden contener errores de medida, aproximaciones, o autoinformes poco fiables. Por tanto, el concepto de "ground truth" en la evaluación tiene un carácter idealizado que conviene tener presente.
- Además, el estudio ha centrado su evaluación en **un conjunto limitado de modelos de clasificación**: k-NN, regresión logística y Random Forest. Aunque representan una gama razonable de complejidad y estilos (instancia-based, lineal y ensemble), no se han explorado modelos como **XGBoost**, **redes neuronales** o **métodos bayesianos**, que podrían interactuar de forma diferente con las imputaciones. Esta restricción puede influir en la generalización de los hallazgos a otros contextos donde se usen algoritmos distintos.
- También se ha trabajado con una **selección de variables reducida** (34), resultado de un proceso de limpieza previo. Si bien esto favorece la claridad experimental y reduce el ruido, limita también la diversidad de situaciones a las que se enfrenta la imputación. Por ejemplo, no se han evaluado casos con alta cardinalidad categórica, estructuras jerárquicas, o variables longitudinales, todos ellos comunes en estudios epidemiológicos.
- Por último, la **evaluación se ha centrado exclusivamente en el rendimiento predictivo** posterior a la imputación. No se han considerado métricas específicas de imputación (como el RMSE entre valores reales e imputados), ni se ha analizado la estabilidad de los valores imputados bajo perturbaciones. Aunque esta elección es coherente con el objetivo aplicado del estudio (predecir diabetes tras imputar), deja fuera otros enfoques de validación que podrían ser útiles en entornos donde la fidelidad de los datos es tan importante como la capacidad de predicción.

Estas limitaciones no restan valor a los resultados, pero sí ofrecen un marco crítico para interpretar su alcance. En el siguiente apartado se compararán los hallazgos con los de

estudios previos, lo que permitirá contextualizar aún mejor los puntos fuertes y débiles observados.

5.3. Comparación con estudios anteriores

Los resultados obtenidos en este estudio presentan varias similitudes, pero también algunas divergencias relevantes, respecto a los trabajos previos sobre imputación de datos en entornos biomédicos. Una referencia fundamental en este campo es el *benchmark* propuesto por **Jäger et al. (2021)**, que evaluó una amplia variedad de métodos de imputación sobre múltiples datasets reales, incluyendo tanto datos clínicos como poblacionales.

En línea con las conclusiones de Jäger et al., este trabajo confirma la **superioridad general de MissForest** en múltiples escenarios. En ambos estudios, este método basado en bosques aleatorios destaca por su robustez frente a distintos patrones de ausencia y su rendimiento sostenido en tareas de predicción posteriores. También coincide con la literatura en considerar que los **métodos simples** (media, mediana), aunque limitados, pueden ofrecer un **rendimiento competitivo** cuando las condiciones del problema no son extremas.

Sin embargo, se aprecian **diferencias notables en lo relativo a GAIN**. En el estudio de Jäger et al., esta técnica basada en redes generativas no adversariales mostró un rendimiento muy variable y en algunos casos inferior al de métodos más tradicionales, lo que los llevó a concluir que no era una opción recomendable en entornos clínicos reales. En contraste, en el presente estudio, GAIN ha ofrecido un rendimiento excelente y muy consistente, situándose sistemáticamente entre los mejores métodos en todas las métricas, especialmente cuando se combina con modelos potentes como Random Forest. Esta discrepancia puede deberse a varios factores: en primer lugar, al diseño más controlado del presente experimento, que permite que GAIN aproveche sus capacidades de modelado profundo sin enfrentarse a problemas de escasez de datos o alta dimensionalidad. En segundo lugar, podría influir el hecho de que NHANES presenta una estructura multivariada densa, bien alineada con las capacidades de GAIN.

En cuanto al comportamiento de las métricas, este estudio confirma la idea —ya sugerida en la literatura— de que **la AUC-ROC puede sobreestimar el rendimiento** de los modelos en presencia de clases muy desbalanceadas, y que es recomendable combinarla con métricas como PR AUC y F1-score para obtener una visión más matizada. Este enfoque es coherente con otros trabajos recientes que abogan por una evaluación múltiple en problemas de clasificación binaria con baja prevalencia de la clase positiva (Chicco & Jurman, 2020; Saito & Rehmsmeier, 2015).

Por último, cabe señalar que este estudio aporta una **contribución original al comparar de forma sistemática el rendimiento por mecanismo de ausencia (MCAR, MAR, MNAR)**, algo que la mayoría de benchmarks anteriores no abordan de forma diferenciada. Esta dimensión adicional permite una interpretación más contextualizada de los resultados y puede tener implicaciones prácticas relevantes, como se discutirá en el siguiente apartado.

5.4. Aplicabilidad en entornos clínicos y epidemiológicos

Más allá del rendimiento observado en contextos simulados, es fundamental preguntarse qué métodos de imputación pueden resultar realmente útiles en entornos clínicos o epidemiológicos reales, donde los recursos son limitados, los datos pueden estar sucios o mal estructurados, y las decisiones tienen consecuencias prácticas.

Uno de los aspectos clave a considerar es la **robustez frente a mecanismos de ausencia poco controlables**, como los MNAR. En muchos estudios médicos o de salud pública, las variables ausentes no lo están al azar, sino que su omisión está relacionada con factores sensibles o estigmatizantes (por ejemplo, consumo de alcohol, ingresos, enfermedades previas). En estos casos, métodos como MissForest o GAIN han mostrado mayor capacidad de adaptación, aunque GAIN puede requerir ajustes finos para no generar imputaciones irreales en situaciones límite.

Otro aspecto relevante es la **viabilidad computacional**. Algunos algoritmos como GAIN o MICE pueden ser costosos en tiempo y recursos, especialmente con grandes volúmenes de datos. En aplicaciones hospitalarias o sistemas de vigilancia epidemiológica, donde la imputación debe integrarse en pipelines automatizados y con tiempos de respuesta rápidos, este factor puede ser decisivo. Métodos más sencillos como la media, la mediana o incluso kNN pueden ofrecer soluciones suficientemente buenas con un coste marginal, especialmente si se aplican en entornos de screening o preprocesamiento preliminar.

La **interpretabilidad** también juega un papel central. En ámbitos clínicos, donde los profesionales necesitan comprender y justificar las decisiones, los métodos basados en imputaciones simples o en modelos transparentes pueden resultar preferibles a técnicas más opacas como GAIN. MissForest, aunque algo más compleja, ofrece imputaciones consistentes con la lógica médica y puede ser visualizada a través de árboles de decisión.

Además, en estudios epidemiológicos longitudinales, donde la estructura temporal y la multicolinealidad son frecuentes, la elección del método debe considerar la capacidad de preservar patrones de dependencia en el tiempo. Aunque este aspecto no se ha evaluado directamente en el presente trabajo, puede tener implicaciones importantes sobre la generalización de los hallazgos. En este sentido, algunos métodos podrían beneficiarse de ser adaptados para integrar información temporal o estructural, lo cual abre la puerta a variantes híbridas o guiadas por conocimiento experto.

En conjunto, los resultados de este estudio permiten orientar la selección de métodos en función del escenario de aplicación. En contextos con buena infraestructura técnica y tiempo de cómputo suficiente, MissForest y GAIN son candidatos naturales. En situaciones donde la rapidez, la simplicidad o la necesidad de transparencia priman, los métodos simples siguen siendo opciones válidas, especialmente si los patrones de ausencia no son extremos.

6. Conclusiones

6.1. Principales hallazgos del estudio

Este trabajo ha permitido extraer una serie de hallazgos relevantes tanto desde el punto de vista metodológico como aplicado. A continuación, se presentan de forma estructurada las principales conclusiones obtenidas tras el análisis de los resultados:

- **El rendimiento de los métodos de imputación depende en gran medida del modelo utilizado.** Mientras que algoritmos como GAIN y MissForest muestran una mejora generalizada con todos los clasificadores, los métodos simples (media, mediana) solo alcanzan su máximo potencial con modelos potentes como Random Forest. En clasificadores más limitados (k-NN o regresión logística), la elección del imputador se vuelve más determinante.
- **GAIN y MissForest son los imputadores más eficaces y consistentes**, destacando en todas las métricas (F1-score, AUC-ROC, PR AUC), incluso en escenarios adversos como MCAR o MNAR. Sin embargo, esta ventaja es especialmente clara cuando se combinan con modelos capaces de aprovechar estructuras complejas, como Random Forest.
- **Los métodos simples presentan una robustez sorprendente**, especialmente la mediana, que se comporta notablemente bien incluso en situaciones complejas como MNAR. Su rendimiento, unido a una baja variabilidad y coste computacional nulo, los convierte en alternativas válidas en aplicaciones reales donde se priorice la estabilidad y/o la transparencia.
- **MICE y el imputador kNN presentan una alta variabilidad y un rendimiento más inestable**, lo que los hace menos recomendables en entornos sensibles o cuando no se pueda validar su comportamiento caso por caso. Especialmente MICE ha mostrado un rango muy amplio de F1-score, con fuertes caídas bajo MCAR o MNAR.
- **El mecanismo de generación de valores faltantes afecta notablemente al rendimiento.** Contra lo que podría esperarse, MCAR ha sido el mecanismo más perjudicial para todos los métodos, mientras que MNAR ha ofrecido mejores resultados con algunos imputadores, probablemente por la estructura predecible de los valores extremos eliminados.
- **La proporción de valores faltantes influye significativamente en el rendimiento.** A medida que aumenta el porcentaje de ausencia, el F1-score decrece, pero los métodos avanzados (MissForest, GAIN) resisten mejor esta degradación. En cambio, imputadores como MICE y kNN muestran mayor deterioro en escenarios de alta pérdida.
- **MissForest ha demostrado ser el método más robusto ante cualquier combinación de porcentaje y mecanismo de ausencia.** GAIN también mantiene un buen rendimiento, especialmente en MAR y MCAR, mientras que la mediana sorprende positivamente en MNAR.
- **La elección del modelo de clasificación tiene más impacto que la del imputador, siempre que se utilicen métodos razonables.** Random Forest ha liderado los

resultados globales en todas las métricas, mostrando una gran capacidad para absorber tanto imputaciones simples como complejas.

- **Las métricas de evaluación han mostrado una alta correlación, pero no son redundantes.** Aunque F1-score, PR AUC y AUC-ROC tienden a coincidir en la identificación de los mejores métodos y modelos, cada una aporta matices diferentes. En particular, la PR AUC se ha mostrado más sensible al comportamiento sobre la clase minoritaria, lo que refuerza su utilidad en escenarios con desbalance de clases. Esta complementariedad valida el uso de múltiples métricas para una interpretación más completa.
- **El uso de SMOTE ha contribuido de forma positiva al rendimiento predictivo en general, especialmente en términos de F1-score.** Su efecto ha sido más marcado en el dataset completo y con modelos como Random Forest, donde ha permitido mejorar la detección de la clase minoritaria. Si bien su impacto en otras métricas como la PR AUC ha sido más discreto y variable, no se han observado efectos negativos consistentes que cuestionen su utilidad, lo que respalda su incorporación en contextos con desbalance de clases.
- **Los radar plots confirman el dominio de ciertas combinaciones específicas**, como GAIN + Random Forest o MissForest + Random Forest, que se imponen de forma clara y equilibrada en todas las métricas. Estas combinaciones destacan visualmente como las más completas y fiables.
- **No existe un método de imputación universalmente óptimo.** El rendimiento depende no solo del imputador, sino de su interacción con el modelo, del mecanismo de ausencia, del porcentaje de datos perdidos y de la métrica evaluada. Esto subraya la necesidad de adaptar las decisiones metodológicas al contexto específico.

En conjunto, los resultados obtenidos no solo refuerzan lo observado en estudios previos, sino que aportan nuevas evidencias sobre el comportamiento de los métodos de imputación en situaciones complejas. A partir de estos hallazgos se proponen, a continuación, una serie de recomendaciones prácticas y mejoras metodológicas orientadas a futuras aplicaciones.

6.2. Recomendaciones sobre imputación en datos biomédicos

A partir de los resultados y hallazgos obtenidos, pueden establecerse una serie de recomendaciones orientadas a guiar la imputación de valores faltantes en contextos biomédicos reales. Estas sugerencias no pretenden ser normativas, pero sí ofrecer una orientación fundamentada para distintas situaciones prácticas:

- **En estudios con buena capacidad computacional y recursos técnicos, los métodos avanzados como MissForest o GAIN deben ser priorizados.** Su rendimiento ha sido sistemáticamente superior y su capacidad de adaptación a estructuras complejas los convierte en opciones ideales cuando se dispone de infraestructura suficiente y se busca la máxima precisión.
- **En entornos donde la transparencia, la estabilidad o la velocidad de ejecución sean críticas**, los métodos simples como la mediana o incluso la media ofrecen una alternativa válida. Han demostrado una robustez notable, sobre todo cuando se

combinan con modelos potentes como Random Forest, y su bajo coste los hace muy adecuados para pipelines operativos.

- **La elección del imputador debe adaptarse al modelo de clasificación final.** No todos los modelos son capaces de aprovechar la complejidad de las imputaciones avanzadas. Random Forest se ha mostrado muy competente en absorber la riqueza de métodos como GAIN, mientras que clasificadores más simples (como k-NN o regresión logística) no han experimentado grandes mejoras con técnicas sofisticadas.
- **Es esencial considerar el tipo de mecanismo de ausencia subyacente.** Si se sospecha que los datos faltan de forma estructurada (por ejemplo, por omisión deliberada o vergüenza social), métodos robustos como MissForest o la mediana pueden ser especialmente eficaces. En cambio, si los datos faltan al azar, la imputación es más difícil, y es recomendable evitar métodos altamente sensibles como MICE o imputación por kNN.
- **En presencia de desbalanceo de clases, el uso de técnicas de sobremuestreo como SMOTE puede mejorar el rendimiento, especialmente en F1-score.** Aunque su efecto en PR AUC ha sido más neutro, no se han observado efectos negativos sistemáticos, por lo que su inclusión es recomendable cuando se busca aumentar la sensibilidad del modelo hacia la clase minoritaria.
- **No existe una única solución óptima para todos los problemas.** La decisión sobre qué método utilizar debe basarse en una combinación de factores: características del dataset, tipo de variables, modelo final de clasificación, mecanismo de ausencia y objetivos del análisis. La imputación es una herramienta poderosa, pero su eficacia depende del contexto.

6.3. Propuesta de mejoras metodológicas

Los resultados obtenidos y las limitaciones identificadas a lo largo de este trabajo permiten esbozar algunas **mejoras metodológicas** que podrían implementarse en estudios futuros. Estas propuestas no solo buscan optimizar el rendimiento de la imputación, sino también aumentar la validez y la aplicabilidad de los resultados en contextos reales.

6.3.1. Métodos híbridos de imputación

Una línea prometedora consiste en combinar lo mejor de distintos enfoques a través de **métodos híbridos**, que integren la estabilidad de técnicas simples con la capacidad adaptativa de métodos avanzados. Por ejemplo, una estrategia razonable sería imputar primero con la mediana para obtener un punto de partida robusto, y posteriormente refinar los valores con algoritmos como MissForest o GAIN en las variables más relevantes para el modelo predictivo. Este enfoque secuencial podría equilibrar precisión, velocidad y fiabilidad. También podrían explorarse técnicas de *stacking* entre imputadores, o combinaciones ponderadas en función del tipo de variable o del patrón de ausencia.

6.3.2. Evaluación específica para escenarios MNAR

Aunque el estudio ha simulado valores MNAR de forma controlada, se hace evidente la necesidad de diseñar evaluaciones más específicas y profundas para este tipo de ausencia, especialmente porque es frecuente en datos biomédicos sensibles (como ingresos, alcohol o salud percibida). En particular, sería útil desarrollar métricas de imputación que valoren no solo la precisión predictiva global, sino también la **fidelidad estructural de los valores imputados en subgrupos vulnerables o categorías omitidas**. Este tipo de análisis permitiría determinar si los métodos están rellenando correctamente los huecos más delicados o simplemente generando imputaciones plausibles a nivel agregado.

6.3.3. Incorporación de mecanismos causales

Una mejora más ambiciosa, pero también más valiosa, sería la incorporación de **modelos causales** en el proceso de imputación. Actualmente, la mayoría de los algoritmos operan bajo un enfoque puramente estadístico o de aprendizaje automático, sin tener en cuenta las relaciones causales entre variables. **Integrar conocimiento estructural** (por ejemplo, mediante grafos dirigidos acíclicos o modelos bayesianos estructurados) permitiría generar imputaciones más coherentes con la lógica biomédica, especialmente en escenarios donde las ausencias dependen de factores no observables. Además, facilitaría el análisis posterior mediante modelos explicativos, mejorando la interpretabilidad y la validez de las decisiones clínicas basadas en los datos.

Estas propuestas abren la puerta a una mejora sustancial de los métodos actuales, no solo en términos de rendimiento numérico, sino también en robustez, transparencia y alineación con el conocimiento experto. En la siguiente sección se plantean líneas de trabajo concretas para avanzar en esa dirección.

6.4. Proyectos futuros

A partir del trabajo realizado y de las propuestas metodológicas anteriores, es posible identificar varias líneas de desarrollo que permitirían ampliar, validar o aplicar los hallazgos de este estudio en contextos más exigentes o realistas.

6.4.1. Validación en datasets reales con ground truth

Uno de los retos más importantes en imputación es la **falta de "verdades reales"** sobre los datos perdidos. Aunque la simulación de mecanismos de ausencia ha permitido controlar experimentalmente el proceso, sería especialmente valioso aplicar estas técnicas a datasets reales donde se conozca el valor verdadero de algunos registros inicialmente omitidos, como ocurre en repositorios longitudinales con seguimiento clínico. Este tipo de validación permitiría evaluar no solo el rendimiento predictivo, sino también la calidad directa de las imputaciones generadas.

6.4.2. Aplicación de imputación con deep learning más estable

El uso de GAIN ha mostrado un buen comportamiento en este estudio, pero también cierta dependencia del modelo final y de la arquitectura utilizada. Una línea de futuro consiste en **explorar variantes más estables de imputación basada en redes neuronales**, como VAE (Autoencoders Variacionales), BRITS (Bidirectional Recurrent Imputation) o modelos tipo *Transformer*. Estas arquitecturas podrían ofrecer una mayor capacidad para capturar dependencias temporales o estructurales sin tanta sensibilidad a la configuración inicial.

6.4.3. Integración con modelos explicables (XAI)

Un paso fundamental para llevar estos métodos a entornos clínicos o de salud pública es **integrar la imputación con modelos explicables**, que permitan justificar y auditar tanto el valor imputado como las predicciones obtenidas a partir de ellos. En este sentido, podrían desarrollarse pipelines en los que, tras imputar con métodos avanzados, se apliquen modelos como Explainable Boosting Machines (EBMs), o se utilicen técnicas XAI (SHAP, LIME) para explicar cómo la imputación ha afectado a la decisión final. Esto contribuiría a aumentar la confianza en los sistemas automatizados y su aceptación en entornos sensibles.

A modo de cierre, este trabajo ha ofrecido un análisis detallado sobre cómo distintas estrategias de imputación afectan al rendimiento de modelos predictivos en contextos biomédicos. La metodología empleada y la variedad de escenarios considerados han permitido extraer patrones de comportamiento relevantes, identificar limitaciones y establecer criterios prácticos para la selección de técnicas de imputación. El enfoque adoptado, centrado en la evaluación empírica y sistemática, refuerza la necesidad de adaptar las decisiones metodológicas al contexto específico de cada estudio. A partir de los resultados obtenidos, se abren además diversas líneas de trabajo que permitirán seguir profundizando en este campo en futuras investigaciones

7. Bibliografía

Allison, P. D. (2002). *Missing data*. Sage Publications. https://doi.org/10.4135/9781412985079

Azur, M. J., Stuart, E. A., Frangakis, C., & Leaf, P. J. (2011). Multiple imputation by chained equations: What is it and how does it work? *International Journal of Methods in Psychiatric Research, 20*(1), 40–49. https://doi.org/10.1002/mpr.329

Batista, G., & Monard, M. C. (2003). An analysis of four missing data treatment methods for supervised learning. *Applied Artificial Intelligence, 17*(5–6), 519–533. https://doi.org/10.1080/713827181

Che, Z., Purushotham, S., Cho, K., Sontag, D., & Liu, Y. (2018). Recurrent neural networks for multivariate time series with missing values. *Scientific Reports, 8*, 6085. https://doi.org/10.1038/s41598-018-24271-9

Chicco, D., & Jurman, G. (2020). The advantages of the Matthews correlation coefficient (MCC) over F1 score and accuracy in binary classification evaluation. *BMC Genomics, 21*, Article 6. https://doi.org/10.1186/s12864-019-6413-7

Enders, C. K. (2010). *Applied missing data analysis*. Guilford Press. https://www.guilford.com/books/Applied-Missing-Data-Analysis/Craig-Enders/9781606236390

García-Laencina, P. J., Sancho-Gómez, J. L., Figueiras-Vidal, A. R., & Verleysen, M. (2010). Pattern classification with missing data: A review. *Neural Computing and Applications, 19*(2), 263–282. https://doi.org/10.1007/s00521-009-0295-6

Gondara, G., & Wang, K. (2018). MIDA: Multiple imputation using denoising autoencoders. In *Proceedings of the 31st Canadian Conference on Artificial Intelligence* (pp. 260–265). Springer. https://doi.org/10.1007/978-3-319-89656-4_27

Graham, J. W. (2009). Missing data analysis: Making it work in the real world. *Annual Review of Psychology, 60*, 549–576. https://doi.org/10.1146/annurev.psych.58.110405.085530

Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The elements of statistical learning* (2nd ed.). Springer. https://link.springer.com/book/10.1007/978-0-387-84858-7

Jäger, S., Allhorn, J., & Bange, A. (2021). A benchmark for data imputation methods. *Frontiers in Big Data, 4*, Article 682173. https://doi.org/10.3389/fdata.2021.682173

Little, R. J. A., & Rubin, D. B. (2002). *Statistical analysis with missing data* (2nd ed.). Wiley. https://www.wiley.com/en-us/Statistical+Analysis+with+Missing+Data%2C+2nd+Edition-p-9780471183860

Lu, Y., Chen, M., Wang, Q., & Zhang, Y. (2020). MIDAS: Missing data imputation via denoising autoencoders with self-attention. In *2020 19th IEEE International Conference on Machine Learning and Applications (ICMLA)* (pp. 669–676). IEEE. https://doi.org/10.1109/ICMLA51294.2020.00114

National Center for Health Statistics. (2023). *National Health and Nutrition Examination Survey (NHANES)*. U.S. Department of Health and Human Services, Centers for Disease Control and Prevention. https://www.cdc.gov/nchs/nhanes/

R Core Team. (2023). *R: A language and environment for statistical computing* [Computer software]. R Foundation for Statistical Computing. https://www.R-project.org/

Rubin, D. B. (1976). Inference and missing data. *Biometrika, 63*(3), 581–592. https://doi.org/10.1093/biomet/63.3.581

Saar-Tsechansky, M., & Provost, F. (2007). Handling missing values when applying classification models. *Journal of Machine Learning Research, 8*, 1625–1657. https://www.jmlr.org/papers/volume8/saar07a/saar07a.pdf

Saito, T., & Rehmsmeier, M. (2015). The precision-recall plot is more informative than the ROC plot when evaluating binary classifiers on imbalanced datasets. *PLoS ONE, 10*(3), e0118432. https://doi.org/10.1371/journal.pone.0118432

Schafer, J. L., & Graham, J. W. (2002). Missing data: Our view of the state of the art. *Psychological Methods, 7*(2), 147–177. https://doi.org/10.1037/1082-989X.7.2.147

Stekhoven, D. J., & Bühlmann, P. (2012). MissForest—non-parametric missing value imputation for mixed-type data. *Bioinformatics, 28*(1), 112–118. https://doi.org/10.1093/bioinformatics/btr597

Troyanskaya, A., Cantor, M., Sherlock, G., Brown, P., Hastie, T., Tibshirani, R., Botstein, D., & Altman, R. B. (2001). Missing value estimation methods for DNA microarrays. *Bioinformatics, 17*(6), 520–525. https://doi.org/10.1093/bioinformatics/17.6.520

Twala, B., Jones, M. C., & Hand, D. J. (2008). An empirical comparison of techniques for handling incomplete data using decision trees. *Applied Artificial Intelligence, 22*(8), 673–699. https://doi.org/10.1080/08839510802379634

van Buuren, S., & Groothuis-Oudshoorn, K. (2011). mice: Multivariate imputation by chained equations in R. *Journal of Statistical Software, 45*(3), 1–67. https://doi.org/10.18637/jss.v045.i03

Wickham, H. (2025). *NHANES: Publicly available data from the US National Health and Nutrition Examination Survey* (Version 3.1.0) [R package]. https://CRAN.R-project.org/package=NHANES

Yoon, J., Jordon, J., & van der Schaar, M. (2018). GAIN: Missing data imputation using generative adversarial nets. In *Proceedings of the 35th International Conference on Machine Learning (ICML)* (pp. 5689–5698). https://proceedings.mlr.press/v80/yoon18a.html